

Прикладная статистика

Точечные и Интервальные оценки

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Точечные оценки:
 - метод максимальной апостериорной вероятности;
 - Дельта-метод.
- ▶ Одномерные интервальные оценки:
 - Вывод на основе функции правдоподобия;
 - Построение Неймана;
 - Байесовский доверительный интервал.

Оценка апостериорного максимума



Построение оценки

- ▶ ОМП определяет значения параметров, при которых наши данные наиболее вероятны.
- ▶ На самом деле, мы обычно задаёмся вопросом, какие значения параметров наиболее вероятны:

$$f(\theta|X) = f(X|\theta)g(\theta)/h(X)$$

где f , g и h – соответствующие функции распределения.

- ▶ **Оценка апостериорного максимума (МАР)** определяется как значение $\hat{\theta}_n$ параметра θ , которое максимизирует $f(\theta|X)$.

K. Murphy, Machine Learning: a Probabilistic Perspective

Связь с ОМП

- ▶ МАР и ОМП очевидно связаны:

$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)} = \prod \frac{f(x_i; \theta)g(\theta)}{h(x)} \sim c \prod f(x_i; \theta)g(\theta)$$

- ▶ Логарифмируем:


$$\log f(\theta|X) = \log(g(\theta)) + \sum \log(f(x_i|\theta)).$$

- ▶ Получается, что значение МАР оценки и значение ОМП совпадают с точностью до априорной оценки $\log(g(\theta))$.
- ▶ Как выбрать $g(\theta)$?

Сопряжённые априорные распределения

Функция правдоподобия

Априорное распределение


$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)}$$

Распределение данных $h(X) = \int f(X|\theta)g(\theta) d\theta$

Можно подобрать такое априорное распределение $g(\theta)$, которое не выводит при умножении на $f(x|\theta)$, оставляет $f(\theta|X)$ в том же классе распределений.

Семейство $g(\theta)$ будем называть **сопряжённым** к $f(x|\theta)$.

Задача про монетку (обобщение)

Дано: $s + f$ бросков монет, s раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.


$$\mathcal{P}(p|X) = \frac{\mathcal{P}(X|p)\mathcal{P}(p)}{\mathcal{P}(X)}$$

Для s орлов и f решек

$$\mathcal{P}(X|p) = \binom{s+f}{f} p^s (1-p)^f$$

$$\mathcal{P}(p) = \text{Uniform}(0; 1) = \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1} \equiv \text{Beta}(p, \alpha, \beta)$$

$$B(\alpha, \beta) = \int p^{\alpha-1} (1-p)^{\beta-1}$$



Задача про монетку (обобщение)

$$\mathcal{P}(p|X) = \frac{\mathcal{P}(X|p)\mathcal{P}(p)}{\mathcal{P}(X)}$$

Перемножив и нормировав, получим

$$\mathcal{P}(p|X) = \frac{1}{B(s+\alpha, f+\beta)} p^{s+\alpha-1} (1-p)^{f+\beta-1} \equiv \text{Beta}(p, \alpha + s, \beta + f)$$

Beta – **сопряжённое априорное распределение** для распределения Бернулли.

Теорема Бернштейна-фон Мизеса

Для некоторого априорного распределения, выборки D_n из n элементов и регулярной модели, апостериорное распределение:

$$\mathcal{P}(p|D_n) \sim N(\theta^*; I^{-1}(\theta^*)), n \rightarrow \infty,$$

где θ^* - оценка максимального правдоподобия, а I – информация Фишера.

Означает ли это, что байесовская интерпретация проверяется частотной?

Не обязательно ☹️

Изи: G. Young, R.L. Smith Essentials of Statistical Inference (sec 9.12)

Не изи: Van der Vaart, Asymptotic Statistics (sec. 10.2)

Вывод

- ▶ MAP позволяет учесть предыдущие измерения.
- ▶ Результат MAP зависит от параметризации.
- ▶ Подбор* априорного распределения может значительно ускорить решение некоторых задач:
 - в огромном количестве прикладных задач используются более сложные модели, что заставляет заниматься численным интегрированием.

Дельта метод



Мотивация

Пусть есть выборка $x_1, \dots, x_N \sim \text{Bernoulli}(p)$.

- ▶ Чему равна вероятность успеха?

 - p

- ▶ Каковы шансы на успех?

 - $\frac{p}{1-p}$

Как строить оценку для отношения? Как построить дисперсию этой оценки?

G. Casella, R. Berger Statistical inference, sec 5.

Идея решения

- ▶ $T = (T_1, \dots, T_k)$ - с.в. со средними $\theta = (\theta_1, \dots, \theta_k)$. Для дифференцируемой $g(T)$ найдём дисперсию.
- ▶ Пусть $g'_i(\theta) = \frac{\partial}{\partial t_i} g(t)|_{t_1=\theta_1; \dots; t_k=\theta_k}$
- ▶ Разложим

$$g(t) \approx g(\theta) + \sum_{i=1}^k g'_i(\theta)(t_i - \theta_i).$$

Идея получения дисперсии

$$g(t) \approx g(\theta) + \sum_{i=1}^k g'_i(\theta)(t_i - \theta_i).$$

- ▶ Матожидание:

$$\mathbb{E}_{\theta} g(T) = g(\theta).$$

- ▶ Дисперсия

$$\begin{aligned} \text{Var}_{\theta} g(T) &\approx \mathbb{E}_{\theta} \left((g(T) - g(\theta))^2 \right) \approx \mathbb{E}_{\theta} \left(\sum_{i=1}^k g'_i(\theta)(T_i - \theta_i) \right)^2 = \\ &= \sum_{i=1}^k [g'_i(\theta)]^2 \text{Var}_{\theta} T_i + 2 \sum_{i>j} g'_i(\theta) g'_j(\theta) \text{Cov}_{\theta}(T_i, T_j). \end{aligned}$$

Оценка дисперсии шансов выигрыша

Вернёмся к мотивирующему примеру, нас интересовала дисперсия оценки $\frac{\hat{p}}{1-\hat{p}}$. Здесь $g(p) = \frac{p}{1-p}$. Используя предыдущие выкладки несложно подсчитать, что:

$$\text{Var} \left(\frac{\hat{p}}{1-\hat{p}} \right) \approx [g'(p)]^2 \text{Var}(\hat{p}) = \left[\frac{1}{(1-p)^2} \right]^2 \frac{p(1-p)}{n} = \frac{p}{n(1-p)^3}.$$

Оценка дисперсии шансов выигрыша

X - случайная величина, с ненулевым матожиданием μ .

Необходимо оценить матожидание и дисперсию для оценки:

$$g(\mu) = 1/\mu.$$

Используя:

$$E_{\mu}(g(X)) \approx g(\mu),$$

$$\text{Var}_{\mu}(g(X)) \approx [g'(\mu)]^2 \text{Var}_{\mu}(X).$$

Получаем:

$$E_{\mu}\left(\frac{1}{X}\right) \approx \frac{1}{\mu},$$

$$\text{Var}_{\mu}\left(\frac{1}{X}\right) \approx \frac{1}{\mu^4} \text{Var}_{\mu}(X).$$

Дельта-метод

Пусть Y_n — последовательность случайных величин для которых $\sqrt{n}[Y_n - \theta] \rightarrow \mathcal{N}(0, \sigma^2)$ по распределению. Тогда для дифференцируемой в θ функции $g(\cdot)$ с ненулевой производной, $\sqrt{n}[g(Y_n) - g(\theta)] \rightarrow \mathcal{N}(0, \sigma^2[g'(\theta)]^2)$ по распределению.

Пример (продолжение)

Продолжим предыдущий пример. Пусть есть выборка со средним $\bar{X}$, тогда:

$$\sqrt{n} \left(\frac{1}{\bar{X}} - \frac{1}{\mu} \right) \rightarrow \mathcal{N} \left(0, \left(\frac{1}{\mu} \right)^4 \text{Var}_{\mu} X_1 \right) \text{ по распределению}$$

Если мы не знаем матожидание и дисперсию, можно ввести их оценку:

$$\widehat{\text{Var}} \left(\frac{1}{\bar{X}} \right) \approx \left(\frac{1}{\bar{X}} \right)^4 S^2,$$

то есть

$$\frac{\sqrt{n} \left(\frac{1}{\bar{X}} - \frac{1}{\mu} \right)}{\left(\frac{1}{\bar{X}} \right)^2 S} \rightarrow \mathcal{N}(0, 1)$$

Вывод

- ▶ Дельта метод позволяет оценить дисперсию функций случайной величины.
- ▶ Важное свойство – асимптотическое поведение такой оценки.
- ▶ Следует учитывать наличие (возможно больших) следующих членов разложения.

Доверительные интервалы



Зачем нужны доверительные интервалы

- ▶ Точечные оценки могут быть интересны для быстрого вывода или для использования в дальнейшем анализе.
- ▶ Обычно хотим также получить оценку как далеко находится настоящее значение параметра.




Y. Puwitan In all Likelihood, Chap 2-3
М. Б. Лагутин, Наглядная математическая статистика

Интерпретации интервалов (классическая)

- ▶ Confidence interval.
- ▶ Две статистики $\hat{\theta}_L$ и $\hat{\theta}_R$ определяют границы **доверительного интервала** для параметра θ с **коэффициентом доверия** $1 - \alpha$ если при всех $\theta \in \Theta$ для выборки $X = \{X_i\}$ из закона распределения $F_\theta(x)$ справедливо :

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X)) = 1 - \alpha.$$





60 экспериментов $x \sim N(\mu = 5; \sigma = 0.1)$.
95% интервал в эксперименте: $(\bar{x} \pm 0.116)$
 $3/60 \approx 0.05$ интервалов не содержат настоящее значение

Интерпретации интервалов (байесовская)

- ▶ Credible interval.
- ▶ $[L, R]$ определяют **Байесовский доверительный интервал** с коэффициентом доверия $1 - \alpha$, к которому значение параметра θ принадлежит с апостериорной вероятностью $1 - \alpha$:

$$\mathcal{P}(L < \theta < R|X) = 1 - \alpha.$$



Интервалы: выводы

Классическая

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X)) = 1 - \alpha.$$

- ▶ говорит о поведении экспериментов в асимптотическом случае;
- ▶ вопрос: как **будут** вести себя наши оценки, если мы будем повторять наш эксперимент много раз?

Байесовская

$$\mathcal{P}(L < \theta < R|X) = 1 - \alpha.$$

- ▶ говорит о нашем суждении о значении параметра;
- ▶ вопрос: какое значение параметра мы можем предположить **после этого эксперимента?**

Частотное покрытие интервала

- ▶ **Экспериментальная вероятность покрытия (coverage probability, coverage)** интервальной оценки – вероятность того, что в интервальной оценке содержится настоящее значения параметра:

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X))$$

- ▶ В идеале равна коэффициенту доверия $1 - \alpha$.
- ▶ В реальности используем асимптотические методы.

Типология проблем

Перепокрытие (overcoverage, conservative)

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X)) > 1 - \alpha.$$

- ▶ погрешности завышены;
- ▶ снижает чувствительность эксперимента.

Недопокрытие (Undercoverage, optimistic)

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X)) < 1 - \alpha.$$

- ▶ погрешности занижены;
- ▶ увеличивает вероятность ошибочного вывода.

Доверительные интервалы на основе функции правдоподобия



Нормальная теория

Пусть мы берём $X \sim N(\mu; \sigma^2)$. Для известных μ и σ^2 :

$$\beta = \mathbb{P}(a \leq X \leq b) = \int_a^b N(\mu, \sigma^2) dX'.$$


При этом, если μ неизвестна, мы больше не сможем подсчитать этот интеграл, вместо этого мы можем оценить вероятность $[\mu + c, \mu + d]$:

$$\begin{aligned} \beta = \mathbb{P}(\mu + c < X < \mu + d) &= \int_{\mu+c}^{\mu+d} N(\mu, \sigma^2) dX' = \\ &= \int_{c/\sigma}^{d/\sigma} \frac{1}{\sqrt{2\pi}} \exp\left[\frac{1}{2}Y^2\right] dY. \end{aligned}$$

То есть, мы можем переписать как $\beta = \mathbb{P}(X - d \leq \mu \leq X - c)$

F. James, Statistical methods in Experimental Physics

Анализ функции правдоподобия





Log-likelihood function for Gaussian X , distributed $N(\mu, \sigma^2)$.

- ▶ 1 событие $X \sim N(\mu; \sigma)$, σ известно.
- ▶ $\log \mathcal{L}(X|\mu) = \log c - \frac{(\mu - x)^2}{2\sigma^2}$.
- ▶ 68%-Доверительный интервал имеет границы
$$\hat{\theta}_L \rightarrow X - \sigma(\log \mathcal{L} - 1/2);$$
$$\hat{\theta}_R \rightarrow X + \sigma(\log \mathcal{L} + 1/2).$$

Инвариантность функции правдоподобия

ОМП не зависит от параметризации, то есть $\hat{\theta}_n$ — ОМП для θ , тогда $g(\hat{\theta}_n)$ — ОМП для $g(\theta)$; *




Также можно анализировать несимметричные случаи и случаи с многими максимумами.

*На самом деле, нужно использовать теорему Вилкса и t-интервалы, оставим это на потом

Проверка

- ▶ Многократная симуляция выборки с фиксированными параметрами.
- ▶ Для каждой выборки построим интервал.
- ▶ Подсчитаем количество интервалов, содержащих настоящее значение параметров.



Выводы

- ▶ Вывод на основе функции правдоподобия позволяет быстро получить интервалы для интересующего параметра.
- ▶ Эти интервалы не обязательно имеют нужные **частотные** характеристики.
- ▶ Существуют методы, исправляющие поведение интервалов. Этим методы тоже необходимо валидировать.


Построение Неймана



Идея

- ▶ При оценке какого-то параметра обычно у нас есть параметрическая модель данных $P(X|m_0)$.
- ▶ Можно использовать эту модель для получения p -значения:
$$p(x) = P(X > x|m) \text{ или } p(x) = P(X < x|m)$$
- ▶ Затем получить для уровня доверия $1 - \alpha$ $p_{1-\alpha}(m)$.
- ▶ Построить доверительный интервал, инвертировав тест.


Графический вывод



- ▶ модель данных $P(X|m_0)$;
- ▶ $p(x) = P(X > x|m)$,
 $p(x) = P(X < x|m)$.
- ▶ для уровня доверия $1 - \alpha$ $p_{1-\alpha}(\theta)$;
- ▶ Построить доверительный интервал, инвертировав тест.

$$m \in [m_1; m_2] @ (1 - \alpha) \text{ CL}$$

Проблемы построения – гибридный подход



- ▶ пустые интервалы;
- ▶ поведение около границ.

Решение –
использование
семплирования
вблизи границ.

Выводы

- ▶ Построение (Неймана) позволяет получить идеальное покрытие в простых случаях.
- ▶ Вблизи границ ситуация усложняется.
- ▶ В любом случае необходимо тестирование вероятности покрытия в рабочих точках вывода.
- ▶ Для дискретных распределений аналогом является интервал Клоппера-Пирсона.

Байесовский доверительный интервал




Построение доверительного интервала

Байесовский подход:


$$1 - \alpha = \int_{\theta_{lo}}^{\theta_{up}} p(\theta|X) d\theta$$

Подходы к выбору θ_{lo} и θ_{hi} :

- › HPD (highest probability density) — брать только наиболее высокие вероятности.
- › Центральный интервал - интегрировать от пика.
- › Односторонний интервал — интегрировать от бесконечности.



Поведение интервала вблизи границы



Bayesian 90% Upper Limits (Uniform Prior)

observed =	0	1	2	3
background = 0.0	2.30	3.89	5.32	6.68
0.5	2.30	3.50	4.83	6.17
1.0	2.30	3.26	4.44	5.71
2.0	2.30	3.00	3.87	4.92
3.0	2.30	2.83	3.52	4.37

Поведение вблизи границ получается в байесовском подходе очень просто — мы используем априорное распределение с информацией о физической границе.

Полученные результаты очень логичны, если использовать плоское априорное распределение с чёткой левой границей.

Вывод

- ▶ Байесовский вывод органично обходит все проблемы построения доверительных интервалов.
- ▶ Априорные знания в данном случае помогают легко интегрировать нужную информацию.

Выводы

- ▶ При нахождении значения параметров важны не (с)только точечные оценки, но и интервальные.
- ▶ Интервальные оценки могут быть построены байесовским и частотным методом, их смысл отличается и они имеют разные проблемы.