

Прикладная статистика

Многомерный вывод

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Одномерные интервальные оценки:
 - Построение Неймана;
 - Байесовский доверительный интервал.
- ▶ Многомерные интервальные оценки:
 - маргинализация;
 - профилирование;
 - особенности частотных многомерных оценок.

Построение Неймана



Идея


- ▶ При оценке какого-то параметра обычно у нас есть параметрическая модель данных $P(X|m_0)$.
- ▶ Можно использовать эту модель для получения p -значения:
$$p(x) = P(X > x|m) \text{ или } p(x) = P(X < x|m)$$
- ▶ Затем получить для уровня доверия $1 - \alpha$ $p_{1-\alpha}(m)$.
- ▶ Построить доверительный интервал, инвертировав тест.

Важно: способы построения интервалов в шаге 2 могут быть любые

Y. Puwitan In all Likelihood, Chap 2-3

М. Б. Лагутин, Наглядная математическая статистика


Графический вывод



- ▶ модель данных $P(X|m_0)$;
- ▶ $p(x) = P(X > x|m)$,
 $p(x) = P(X < x|m)$.
- ▶ для уровня доверия $1 - \alpha$ $p_{1-\alpha}(\theta)$;
- ▶ Построить доверительный интервал, инвертировав тест.

$$m \in [m_1; m_2] @ (1 - \alpha) \text{ CL}$$

Проблемы построения – гибридный подход



- ▶ пустые интервалы;
- ▶ поведение около границ.

Решение –
использование
семплирования
вблизи границ.

Выводы

- ▶ Построение (Неймана) позволяет получить идеальное покрытие в простых случаях.
- ▶ Вблизи границ ситуация усложняется.
- ▶ В любом случае необходимо тестирование вероятности покрытия в рабочих точках вывода.
- ▶ Для дискретных распределений аналогом является интервал Клоппера-Пирсона.



Байесовский доверительный интервал



Интерпретации интервалов (байесовская)

- $[L, R]$ определяют **Байесовский доверительный интервал** с коэффициентом доверия $1 - \alpha$, к которому значение параметра θ принадлежит с апостериорной вероятностью $1 - \alpha$:

$$\mathcal{P}(L < \theta < R|X) = 1 - \alpha.$$



• Biological Conservation 165:10–17

Есть ли в байесовском интервале вероятность покрытия?

F. James, Statistical methods in Experimental Physics


Построение доверительного интервала

Байесовский подход:


$$1 - \alpha = \int_{\theta_{lo}}^{\theta_{up}} p(\theta|X) d\theta$$

Подходы к выбору θ_{lo} и θ_{hi} :

- › HPD (highest probability density) — брать только наиболее высокие вероятности.
- › Центральный интервал - интегрировать от пика.
- › Односторонний интервал — интегрировать от бесконечности.



Построение интервала вблизи границы



Bayesian 90% Upper Limits (Uniform Prior)

observed =	0	1	2	3
background = 0.0	2.30	3.89	5.32	6.68
0.5	2.30	3.50	4.83	6.17
1.0	2.30	3.26	4.44	5.71
2.0	2.30	3.00	3.87	4.92
3.0	2.30	2.83	3.52	4.37

Поведение вблизи границ получается в байесовском подходе очень просто — мы используем априорное распределение с информацией о физической границе.

Полученные результаты очень логичны, если использовать плоское априорное распределение с чёткой левой границей.

Несобственные априорные вероятности

В процессе определения границ эксперимента, мы заботились только о левой границе. А что происходит с правой? Должна ли она быть на бесконечности? в таком случае:

$$\int_b^a \text{Uniform}(x) dx = 0, \forall a, b$$

То есть мы должны также ограничивать правую сторону, причём о ней у нас нет (или почти нет информации).

Кроме того, использование плоского априорного распределения довольно случайно ;-)

Априорная вероятность Джеффриса

Изначально вводилась так, чтобы быть инвариантной относительно некоторых преобразований координат. Для каждого семейства кривых, вероятность Джеффриса может быть подсчитана из этого условия. Например, для распределения Пуассона Джеффрис предлагал её сделать инвариантной к масштабу $\sim 1/\mu$.

Bayesian 90% Upper Limits ($1/\mu$ Jeffreys Prior)

observed =	0	1	2	3
background = 0.0	0.00	2.30	3.89	5.32
0.5	0.00	0.00	0.00	0.00
1.0	0.00	0.00	0.00	0.00
2.0	0.00	0.00	0.00	0.00
3.0	0.00	0.00	0.00	0.00

Вывод

- ▶ Байесовский вывод органично обходит все проблемы построения доверительных интервалов.
- ▶ Априорные знания в данном случае помогают легко интегрировать нужную информацию.

Многомерный вывод



Мешающие параметры

- ▶ **Мешающий параметр (Nuisance parameters)** – любой неизвестный параметр вероятностного распределения в статистической задаче, связанной с изучением других параметров данного распределения.

Olaf Behnke et al. Data Analysis in High Energy Physics: A Practical Guide to Statistical Methods

Chapter 4: Luc Demortier Interval Estimation

Мешающие параметры: пример



- ▶ Вольтметр, который правильно работает ($a=0,1$) с вероятностью λ . В нормальном состоянии $x \sim N(\theta, 1)$, при сбое $x \sim N(\theta, 1 \times 100)$.
- ▶ Функция распределения:

$$f(x, a; \theta, \lambda) \sim N(x; \theta; 1)1_{a=1}\lambda + \phi\{x; \theta; 100\}1_{a=0}(1 - \lambda).$$

- ▶ Измерение: $x = 4$ В. Совместно ли это с отсутствием напряжения?

$$\begin{aligned} p &= P(X > 4; \theta = 0) = \{1 - \phi(4)\}\lambda + \{1 - \phi(0.4)\}(1 - \lambda) \\ &= 0.00003\lambda + 0.34458(1 - \lambda). \end{aligned}$$

Зависит от неизвестного параметра λ

Байесовский многомерный вывод

- ▶ Для набора параметров $\{\psi; \theta\}$ с интересующим параметром ψ , мешающий θ исключается интегрированием:

$$\mathcal{P}(X|\psi) = \int \mathcal{P}(X; \theta|\psi) \pi(\theta|\psi) d\theta ,$$

где π -- априорное знание ψ .

- ▶ Такое построение называется **маргинализацией**, получается **функция маргинального правдоподобия (marginal)**.

Мешающие параметры: пример

- ▶ Вольтметр проверен и исправен: $\lambda = 1$.
- ▶ Функция распределения:



$$f(x, a; \theta, \lambda) = \phi(x - \theta)1_{a=0}\lambda + \phi\{(x - \theta)/10\}1_{a=1}(1 - \lambda).$$



$$f(x; \theta) = \phi(x - \theta).$$

Способы анализа

$$\mathcal{P}(X|\psi) = \int \mathcal{P}(X; \theta|\psi) \pi(\theta|\psi) d\theta$$

- ▶ Подбор сопряжённого априорного выражения.
- ▶ Прямое численное интегрирование.
- ▶ Интегрирование с выборкой по значимости.
- ▶ Использование MCMC.

Частотный многомерный вывод

- ▶ Хотим получить гарантии на покрытие:

$$\mathcal{P}(\hat{\theta}_L(X) < \theta < \hat{\theta}_R(X)) > 1 - \alpha.$$

- ▶ Использовать построение Неймана:
 - Нужно много CPU.
- ▶ Найти асимптотический метод.
- ▶ Бутстрап.

Профильная функция правдоподобия

- ▶ Для параметров $\theta = (\psi, \lambda)$, для которых известна функция правдоподобия $\mathcal{L}_n(\psi, \lambda)$, построенная на выборке размером n , **профильной функцией правдоподобия** будем называть


$$P\mathcal{L}_n(\psi, \hat{\lambda}) = \operatorname{argmax}_{\lambda} \mathcal{L}_n(\psi, \lambda),$$

где $\hat{\lambda}$ -- оценка максимального правдоподобия λ при фиксированном ψ .

Профилирование

- ▶ Фиксируем ψ .
- ▶ Ищем оптимальное значение $\hat{\lambda}$.
- ▶ Находим значение $P\mathcal{L}_n(\psi, \hat{\lambda})$.
- ▶ Переходим к следующему значению ψ .


$$P\mathcal{L}_n(\psi, \hat{\lambda}) = \operatorname{argmax}_{\lambda} \mathcal{L}_n(\psi, \lambda)$$



R Boiger et al. Integration based profile likelihood calculation for PDE constrained parameter estimation problems, Inverse Problems, 32 12

Профилирование

$$P\mathcal{L}_n(\psi, \hat{\lambda}) = \operatorname{argmax}_{\lambda} \mathcal{L}_n(\psi, \lambda)$$




- ▶ Пути профилирования могут отличаться для разных параметров.
- ▶ Точки начала доверительных интервалов для 1D и 2D не обязательно совпадают.

Мешающие параметры: пример




$$f(x,a;\theta,\lambda) = \phi(x-\theta)1_{a=0}\lambda + \phi\{(x-\theta)/10\}1_{a=1}(1-\lambda).$$



θ_{fix}	0	1	2	3	4	5	6	7	8
a=0	0,000	0,004	0,054	0,242	0,399	0,242	0,054	0,004	0,000
a=1	0,004	0,004	0,004	0,004	0,004	0,004	0,004	0,004	0,004
Max	0,004	0,004	0,054	0,242	0,399	0,242	0,054	0,004	0,004

Маргинализация и профилирование




Figs from C. Weninger

- ▶ В полностью гауссовом случае оба метода совпадают.
- ▶ Асимптотически гауссовы правдоподобия также «почти» совпадают.

Маргинализация и профилирование

- ▶ В случае негауссовых правдоподобий ситуация отличается.
- ▶ Иногда в асимптотическом режиме всё начинает сходиться.



Figs from C. Weninger

Теорема Уилкса

- ▶ Для достаточно хорошей функции правдоподобия $\mathcal{L}_n(\psi, \lambda)$, где $\psi \in \mathbb{R}^k$ и $\lambda \in \mathbb{R}^l$ верно по распределению:

$$-2 \log \frac{P \mathcal{L}_n(\psi, \hat{\lambda})}{\mathcal{L}_n(\hat{\psi}, \hat{\lambda})} \sim \chi_k^2$$

- ▶ Это позволит получать одномерные и многомерные доверительные интервалы.

Теорема Уилкса: 1D


Для построения интервалов в случае одномерной функции правдоподобия необходимо использовать теорему Уилкса:

$$-2\log \frac{\mathcal{L}_n(\psi)}{\mathcal{L}_n(\hat{\psi})} \sim \chi^2_2$$

Это позволит уточнить интервалы, полученные как аналог нормальной теории (в прошлой лекции).

Теорема Уилкса: как сломать

- ▶ Низкое количество событий.
- ▶ Близость к границе.
- ▶ Нерелевантность параметров.



Вывод: профилирование

- ▶ Метод позволяет получить (в том числе численно) одномерное правдоподобие.
- ▶ Теорема Вилкса даёт возможность построить интервалы с использованием профильного правдоподобия.
- ▶ Свойства покрытия лучше соблюдаются для интервалов с малым доверительным значением.
- ▶ Покрытие необходимо проверять на экспериментах.

Выводы

- ▶ Многомерный вывод -- основа современного статистического анализа.
- ▶ Частотные и байесовские результаты зачастую не совпадают именно в этом