

Прикладная статистика

Дисперсионный анализ

Денис Деркач, Али Диб Халед, Эхсан Кадер

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2026

В этой лекции



- ▶ Мотивация
- ▶ Тестируемые гипотезы
- ▶ Дисперсионный анализ
- ▶ Анализ Краскела-Уоллиса
- ▶ Апостериорные тесты

Мотивация



Мотивация


- ▶ Что делать, если необходимо исследовать поведение системы с категориальным признаком?



- ▶ Отличаются ли группы?

Мотивация

- ▶ Как можно разделить эти два случая?



Обсуждение



- ▶ Если события во всех выборках происходят из одного распределения, то все события должны быть распределены одинаково, как внутри группы, так между группами.
- ▶ Это, в частности, означает асимптотическое равенство дисперсий и средних.
- ▶ Необходимо сравнить дисперсию внутри группы с дисперсией между группами, для того, чтобы получить вывод о равенстве средних.

Гипотезы



Постановка задачі

- ▶ $H_0: \mu_1 = \mu_2 = \mu_3$
- ▶ $H_1: \mu_1 \neq \mu_2$ или $\mu_2 \neq \mu_3$ или $\mu_1 \neq \mu_3$



Использование t -тестов

TABLE 1: Probability of Committing at Least One Type I Error by Using Two-Sample t Tests for All C Pairwise Comparisons of k Means*


k	C	Level of Significance, α , Used in the t Tests				
		0.10	0.05	0.01	0.005	0.001
2	1	0.10	0.05	0.01	0.005	0.001
3	3	0.27	0.14	0.03	0.015	0.003
4	6	0.47	0.26	0.06	0.030	0.006
5	10	0.65	0.40	0.10	0.049	0.010
6	15	0.79	0.54	0.14	0.072	0.015
10	45	0.99	0.90	0.36	0.202	0.044
	∞	1.00	1.00	1.00	1.000	1.000

*There are $C = k(k - 1)/2$ pairwise comparisons of k means. This is the number of combinations of k items taken two at a time.

- ▶ Можно взять несколько попарных t -тестов:
- ▶ $H_0: \mu_1 = \mu_2; H_1: \mu_1 \neq \mu_2.$
- ▶ $H_0: \mu_2 = \mu_3; H_1: \mu_2 \neq \mu_3.$
- ▶ вероятность ошибки первого рода резко увеличивается.

Идея

- ▶ При верной H_0 все группы получены из популяций с одинаковыми средним μ и дисперсией σ^2 .
- ▶ Оценим дисперсию разными независимыми способами и сравним.



Двухвыборочный F-тест

Предположим, что у нас есть две iid выборки

$X_1, \dots, X_n \sim \mathcal{N}(\mu_X, \sigma_X^2)$ и $Y_1, \dots, Y_m \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$. Необходимо проверить, что X и Y имеют одинаковую дисперсию.

$$H_0 : \sigma_X^2 = \sigma_Y^2;$$

$$H_a : \sigma_X^2 \neq \sigma_Y^2;$$

Мы можем оценить дисперсии:

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2;$$

$$S_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2$$

Распределение Фишера

Тогда статистика:

$$\frac{S_X^2}{S_Y^2} \sim F(m-1, n-1).$$

Где F - распределение Фишера, характерной функцией плотности вероятности для которого является:


$$f(x; d_1, d_2) = \frac{1}{B\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} \left(\frac{d_1}{d_2}\right)^{\frac{d_1}{2}} x^{\frac{d_1}{2}-1} \left(1 + \frac{d_1}{d_2} x\right)^{-\frac{d_1+d_2}{2}},$$

где B - бета-функция.

Распределение Фишера


$$\frac{S_X^2}{S_Y^2} \sim F(m-1, n-1).$$

- ▶ односторонний;
- ▶ относительно неустойчив к ненормальности распределений;
- ▶ в случае больших α или близких размеров выборок, может проявлять устойчивость, при этом всё равно теряет мощность.



Идея дисперсионного анализа

- ▶ При верной H_0 все группы получены из популяций с одинаковыми средним μ и дисперсией σ^2 .
- ▶ Оценим дисперсию разными независимыми способами и сравним.



Будем сравнивать вариативности внутри группы и вариативности между групп.

Дисперсионный анализ (ANOVA)



Данные

Данные состоят из $N = \sum_{j=1}^k n_j$ наблюдений x_{ij} , по n_j наблюдений в j -й выборке, $j = 1, \dots, k$. Фактически, мы анализируем такую таблицу:

Измерения			
1	2	...	k
x_{11}	x_{12}	...	x_{1k}
x_{21}	x_{22}	...	x_{2k}
...	...	...	...
$x_{n_1 1}$	$x_{n_2 2}$	...	$x_{n_k k}$

Для каждого столбца характерно среднее значение μ_j ,
оцениваемое $\bar{X}_j$

Вариативность между группами

Оценим σ^2 на основе дисперсии средних между группами (посчитаем ошибку среднего, как будто это выборочные средние, и из неё вычислим дисперсию):

$$s_{\bar{x}} = \frac{\sum_j (\bar{X}_j - \bar{\bar{X}})^2}{k - 1}$$

Тогда mean square between groups (MS_B):

$$MS_B = \frac{\sum_j (\bar{X}_j - \bar{\bar{X}})^2 n_j}{k - 1}$$

Количество степеней свободы при этом:

$$DF_B = k - 1,$$

где k — число групп.

Вариативность внутри группы

Mean square within groups = error MS

$$MS_W = \frac{s_1^2 + \dots + s_k^2}{k}$$

Количество степеней свободы при этом:

$$DF_B = N - k,$$

где k — число групп, N — полное число семплов.

F-статистика

$$F = \frac{\text{оценка дисперсии между группами}}{\text{оценка дисперсии внутри групп}} = \frac{MS_B}{MS_W}.$$

Тестирование H_0

- › для заданных df рассчитывается критическое значение F ;
- › на основе групп считается F и сравнивается с критическим значением;
- › если F больше критического — H_0 о равенстве средних в группах отвергается;
- › F - это отношение дисперсий, оно имеет особое распределение, оно всегда положительно; ANOVA — принципиально односторонний тест.

Качество ANOVA

Для того, чтобы понять насколько значим полученный результат в тесте строят два типа переменных:

- › $R^2 = \eta^2 = \frac{SS_B}{SS_T}$, чем выше R^2 , тем больше полученный эффект.
- › $f = \frac{s_{\bar{x}}}{\sqrt{MS_W}}$, чем выше, тем больше полученный эффект.

Дизайн эксперимента

- ▶ Факторы могут быть двух видов:
 - **Fixed.** Рассматриваются именно эти значения фактора. Другие значения не существуют или не интересуют. Пример: пол, время суток и тд.
 - **Random.** Рассматриваются случайно выбранные значения фактора из многих возможных. За пределами исследования существуют другие значения фактора. Пример: происхождение семпла, процент лекарства.
- ▶ **Однофакторный анализ** не чувствует разницы. Для **Многофакторного анализа** это разделение имеет решающее значение..

Допущения ANOVA

- ▶ Выборки должны быть случайными, измерения – независимыми.
- ▶ Размеры групп должны различаться как можно меньше.
- ▶ Нормальность в каждой группе по отдельности.
- ▶ Равенство дисперсий в группах.

Нормальность распределения



Требование нормальности

- ▶ Сделать тест по методу моментов (Обычно достаточно проверить эксцесс и асимметрию).
- ▶ Построить гистограмму распределения остатков $(x_i - \bar{x})$ внутри каждого семпла (и проверить goodness-of-fit тесты).
- ▶ Тест Шапиро-Уилка.
- ▶ Тест Д'Агостино-Пирсона.
- ▶ Тест Андерсона-Дарлинга.

Тест Шапиро-Уилка

Критерий Шапиро-Уилка основан на оптимальной линейной несмещённой оценке дисперсии к её обычной оценке методом максимального правдоподобия. Статистика критерия имеет вид:

$$W = \frac{1}{s^2} \left[\sum_{i=1}^n a_{n-i+1} (x_{n-i+1} - x_i) \right]^2,$$

где $s^2 = \sum_{i=1}^n (x_i - \bar{x})^2$, $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, а коэффициенты a_{n-i+1} берутся из таблиц.

На практике, следует проверять применимость таблиц в том или ином софте. Можно также использовать тест Шапиро-Франча.

Ненормальные данные

- ▶ Если семплы достаточно большие, можно оставить как есть. >
Провести преобразование к нормальным:
 - стандартизовать распределение;
 - метод Бокса-Кокса.
- ▶ Использовать непараметрический ANOVA:
 - односторонний дисперсионный анализ Краскела—Уоллиса.

Метод Бокса-Кокса

Для последовательности: $\{y_1, \dots, y_n\}$, $y_i > 0$ однопараметрическое преобразование Бокса-Кокса с параметром λ определяется следующим образом:

$$y_i^\lambda = \begin{cases} \frac{y_i^\lambda - 1}{\lambda}, & \text{if } \lambda \neq 0, \\ \log(y_i), & \text{if } \lambda = 0. \end{cases}$$

Где λ - свободный параметр.

Одинаковость дисперсий



Требование равенства дисперсий

- ▶ Использовать тест Левеня.
- ▶ Использовать F-тест.
- ▶ Построить зависимость остатков (residuals) от средних.

Требование равенства дисперсий

Проверяет равенство дисперсий всех семплов.

$$W = \frac{(N - k)}{(k - 1)} \cdot \frac{\sum_{i=1}^k N_i (Z_{i\cdot} - Z_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{N_i} (Z_{ij} - Z_{i\cdot})^2},$$

Здесь Z может центрироваться на:

- › среднее выборки (для симметричных распределений);
- › медиану выборки (для асимметричных распределений);
- › усечённое среднее выборки (для распределений с тяжёлыми хвостами).

В общем случае рекомендуют использовать медиану.

Значение W затем сравнивается с соответствующим F распределением.

Анализ Краскела — Уоллиса



Аналог ANOVA

- ▶ непараметрический тест, который не требует нормальности данных (но чувствителен к разным дисперсиям);
- ▶ для двух групп эквивалентен тесту Манна-Уитни;
- ▶ для гетероскедастичных данных, следует использовать дисперсионный анализ Уелча;
- ▶ H_0 : все группы происходят из одного распределения

Алгоритм построения

1. выставить ранг r_{ij} согласно значению всех x_{ij} ;
2. положив:

$$S_j = \sum_{i=1}^{n_j} r_{ij}, r_{.j} = S_j/n_j,$$

тогда

$$r_{..} = 1/N \sum r_{ij} = (N + 1)/2$$

подсчитать статистику:

$$W = \left(\frac{12}{N(N + 1)} \sum_{j=1}^k S_j^2/n_j \right) - 3(N + 1),$$

3. найти критическую область для W -статистики.

Многофакторные параметрические тесты

В случае бОльшего количества факторов можно использовать улучшения теста Краскела-Уоллеса:

- › Scheirer-Ray-Hare Test
- › Jonckheere-Terpstra Test

NB: относительная мощность непараметрических тестов быстро падает с ростом количества факторов.

Непараметрические тесты

- › для $k > 5$ можно сравнивать с χ^2_{k-1} ;
- › для нормальной работы теста рекомендуют $n_i > 5$;
- › H_0 : все группы происходят из одного распределения (Отличается от обычного дисперсионного анализа!).

Апостериорные тесты



Апостериорные (post-hoc) тесты

ANOVA не называет причину, по которой была отвергнута гипотеза H_0 . Потому используют апостериорные тесты:

- › Сначала сравнить все группы между собой с помощью ANOVA.
- › Если различия есть, использовать методы множественного сравнения (сравнивают группы попарно, сохраняя общую $\alpha = 0.05$).
- › Если различий нет, анализ следует считать завершённым (и не проводить post-hoc тесты).

NB: проведение апостериорных тестов может испортить весь анализ.

Тест Тьюки

Он же honestly significant difference test (HSD test) or wholly significant difference test (WSD test).

- › Выстраиваем средние по выборке по возрастанию.
- › Строим статистику $q = \frac{Y_A - Y_B}{SE}$, где Y - среднее (причём $Y_A > Y_B$, SE - стандартное отклонение).
- › Ищем значимость $q_{\alpha, N-k, k}$ для нужного α .

Тест Тьюки

- › Наиболее распространённый и рекомендуемый в литературе тест;
- › строго контролирует α (0.05);
- › проверяет все парные гипотезы сразу;
- › плохо работает, если размер групп сильно различается;
- › чувствителен к неравенству дисперсий;
- › считает статистику (q) на основе MS_{within} и df .

Failed post-hoc

Бывает так, что в ANOVA нулевая гипотеза отвергается, а пост-хок тесты не обнаруживают различий, так как их мощность ниже. В этом случае **необходимо увеличивать размер выборки.**

Заключение

- ▶ Дисперсионный анализ позволяет включить в рассмотрение категориальные переменные.
- ▶ При проведении анализа обязательно проверять условия существования. В лучшем случае нарушения ведут к потере мощности.
- ▶ Возможно включать дополнительно как непрерывные переменные (ANCOVA), так и категориальные (MANOVA, rmANOVA, Nested ANOVA).