

Прикладная статистика

GLM. Диагностика

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Мотивация
- ▶ Коэффициент детерминации
- ▶ Анализ остатков
- ▶ ROC кривая
- ▶ Выбор модели

Мотивация



Экспоненциальное семейство (дисперсионное)

Для $y_1, \dots, y_n$:

$$f(y_i; \theta_i, \phi) = \exp\{[y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)\}$$

θ -- канонический параметр;

ϕ -- дисперсионный параметр;

$b(\cdot)$ -- кумулятивная функция.

- ▶ $\mathbb{E}(Y_i) = b'(\theta_i) = \mu_i$
- ▶ $\text{Var}(Y_i) = b''(\theta_i)a(\phi) = a(\phi)V(\mu)$, $V(\mu)$ - дисперсионная функция.

GLM

Для $f(y; \theta)$, принадлежащему экспоненциальному семейству распределений:

- ▶ **стохастическая** (random) **компонента** $y_i \sim f$;
- ▶ фиксированный линейный предиктор (**систематическая компонента**):

$$\eta_i = \beta_0 + \beta_1 x_{1,i} + \dots + \beta_{p-1} x_{p-1,i} ;$$

- ▶ **функция связи** (link function):

$$g(\mathbb{E}(y_i)) = \eta_i.$$

Критерии качества


- ▶ Получение *абсолютного* качества модели.
- ▶ Отбор переменных.
- ▶ Выбор моделей (получение *относительного* качества модели).

Квартеты Энскомба




Anscombe's Quartet

Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.




Unstructured Quartet

Each dataset here also has the same summary statistics. However, they are not *clearly different* or *visually distinct*.



Все 4 семейства имеют одинаковое среднее, дисперсии, уравнения регрессии, R^2 .

Квартеты Энскомба и Датазавр



Justin Matejka, George Fitzmaurice, Same Stats, Different Graphs, ACM SIGCHI Conference on Human Factors in Computing Systems 2017

Disclaimer: тест χ^2

- ▶ В некоторых пакетах автоматически выводится значения χ^2 теста.
- ▶ Зачастую он показывает не качество модели, а её значимость.
- ▶ Read the docs.

Коэффициент детерминации



Определения коэффициента

- ▶ Хотим обобщить критерии качества, используемые для обычной линейной регрессии.
- ▶ Проблема: в GLM может быть корреляция между дисперсией и средним значением.
- ▶ $P(Y_i = y_i) = \pi_i^{y_i} (1 - \pi_i)^{(1-y_i)}$. То есть:
 - среднее $\mu_i = E(Y_i) = \pi_i$;
 - дисперсия $Var(Y_i) = \pi_i(1 - \pi_i)$

Определения коэффициента

- ▶ Для модели логистической регрессии:

$$\mathcal{P}(y_i = 1) = \mathbb{E}y_i = \pi_i = \frac{\exp(\alpha + \beta x_i + \dots)}{1 + \exp(\alpha + \beta x_i + \dots)};$$

- ▶ сумма квадратов:

$$SS_{RES} = \sum (y_i - \hat{\pi}_i)^2; SS_{MOD} = \sum (\hat{\pi}_i - \bar{y})^2; SS_{TOT} = \sum (y_i - \bar{y})^2.$$

Интерпретация коэффициентов

- ▶ Определения коэффициентов детерминации зависят от интерпретации:
 - $R_{MOD}^2 = \frac{SS_{MOD}}{SS_{TOT}}$ -- объяснённая моделью изменчивость;
 - $R_{RES}^2 = 1 - \frac{SS_{RES}}{SS_{TOT}}$ -- сравнение полной модели с тривиальной;
 - $R_{COR}^2 = r^2(y_i, \hat{\pi}_i)$ -- коэффициент корреляции между предсказаниями и данными.
- ▶ В общем случае, эквивалентны только асимптотически и при правильных коэффициентах модели. При этом хорошо работает в случай НМК и обычной линейной регрессии.

Tue Tjur Coefficients of Determination in Logistic Regression Models
The American Statistician, 63:4, 366-372

Псевдо- R^2

- ▶ Коэффициент дискриминации:

$$D = \bar{\hat{\pi}}_1 - \bar{\hat{\pi}}_0 = \sqrt{R_{MOD}^2 R_{RES}^2} = \frac{1}{2} (R_{MOD}^2 + R_{COR}^2)$$

- ▶ Замена сумм квадратов на правдоподобие:

$$R^2 = 1 - \frac{\ln \hat{\mathcal{L}}_{full}}{\ln \hat{\mathcal{L}}_{intercept}}$$

- ▶ Другие методы основаны на дополнении интерпретаций.

Проблемы R^2

- ▶ Низкие значения для реальных данных:
 - наблюдения всегда $\{0;1\}$, а предсказания могут быть $[0;1]$.
- ▶ Плохо разделяет близкие модели:
 - для $y_i = 0$ модели с $\hat{\pi}_i = 0.9$ и $\hat{\pi}_i = 0.99$ почти не отличаются, а $\mathcal{P}(y_i = 0)$ отличается в 10 раз.

Анализ остатков



Остатки

- ▶ В линейных моделях часто также анализируют остатки:

$$y_i - \hat{y}_i.$$

- ▶ В обобщённых моделях есть несколько схожих способов:

остатки Пирсона (для логрегрессии):

$$r_i = \frac{y_i - \pi_i}{\sqrt{\hat{\pi}_i(1 - \hat{\pi}_i)}}$$

остатки девианса (для логрегрессии):

$$d_i = s_i \sqrt{-2(y_i \log \hat{\pi}_i + (1 - y_i) \log(1 - \hat{\pi}_i))}$$

Из остатков конструируется статистика $D = \sum d^2$ и $X = \sum r^2$.

ДевIANса (Аномальность)

Мотивируясь отношением правдоподобий,

девиансой обобщённой линейной модели называется:

$$D(\hat{\mu}; y) = -2 (\log \mathcal{L}(\hat{\mu}; y) - \log \mathcal{L}(y; y)),$$

где $\hat{\mu}$ -- оценка y .

Девиианса (Аномальность)

- ▶ Для получения шкалы рассматривают два граничных случая:
 - **Насыщенная модель** – каждое уникальное наблюдение описывается одним из n параметров.
 - **Предложенная модель** – модель, подобранная в данном анализе.
 - **Нулевая модель** – все наблюдения описываются одним параметром (средним).
- ▶ Степени свободы (для p параметров модели):

$$df_{\text{saturated}} = 0; df_{\text{model}} = n - p_{\text{model}}; df_{\text{null}} = n - 1;$$

Интерпретация девиансы

Девианса - мера различия правдоподобий двух моделей:

- ▶ Девианса остатков

$$D_{\text{residual}} = 2(\log \mathcal{L}_{\text{saturated}} - \log \mathcal{L}_{\text{model}})$$

- ▶ Девианса нулевой модели

$$D_{\text{null}} = 2 \log \mathcal{L}_{\text{saturated}} - \log \mathcal{L}_{\text{null}}$$

Анализ девиансы

- ▶ Для тестирования значимости модели целиком:

$$LRT = 2 \log \left(\frac{\log \mathcal{L}_{\text{model}}}{\log \mathcal{L}_{\text{null}}} \right) = D_{\text{null}} - D_{\text{residual}}$$
$$df = df_{\text{null}} - df_{\text{model}} = p_{\text{model}} - 1$$

- ▶ Степени свободы (для p параметров):

$$LRT = 2 \log \left(\frac{\log \mathcal{L}_{\text{model}}}{\log \mathcal{L}_{\text{reduced}}} \right) = D_{\text{full}} - D_{\text{residual}}$$
$$df = df_{\text{full}} - df_{\text{model}} = p_{\text{model}} - p_{\text{reduced}}$$

Затем сравнение с χ^2 с df степенями свободы.

Обсуждение


- ▶ Анализ остатков даёт возможность ответить на вопросы о значимости модели и значимости добавления параметра.
- ▶ Аппроксимация χ^2 не очень устойчива, если групп значений у много.
- ▶ Можно использовать методы Хосмера-Лемешова: разбить на группы по вероятности и считать нужны естатистики.

ROC



Обсуждение

- ▶ В специализированном случае регрессий с бинарным выходом, мы можем использовать ROC кривую, как меру качества регрессии.



Матрица смешивания

- ▶ **TP** (True Positive) – correctly predicted positives
- ▶ **FP** (False Positive) – predicted as positives, but negatives (1st order error)
- ▶ **TN** (True Negative) – correctly predicted negatives
- ▶ **FN** (False Negative) – predicted as negatives, but positives (2nd order error)

ACTUAL VALUES

POSITIVE (1)

NEGATIVE (0)


PREDICTIVE VALUES

POSITIVE (1) NEGATIVE (0)

PREDICTIVE VALUES	
POSITIVE (1)	NEGATIVE (0)
ACTUAL VALUES	POSITIVE (1)
	NEGATIVE (0)
POSITIVE (1)	TP
POSITIVE (1)	FN
NEGATIVE (0)	FP
NEGATIVE (0)	TN

Матрица смешивания

- ▶ All positives (**Pos**):
$$Pos = TP + FN$$
- ▶ All negatives (**Neg**):
$$Neg = TN + FP$$
- ▶ All positive predictions (**PosPred**):
$$PosPred = TP + FP$$
- ▶ All negative predictions (**NegPred**):
$$NegPred = TN + FN$$



ROC кривая

- ▶ ROC (Receiver operating characteristic) curve is a dependency of **$TPR(\mu)$** **from $FPR(\mu)$** for different thresholds μ of the probability of positive class p



- ▶ $TPR(\mu)$ (True Positive Rate):

$$TPR(\mu) = \frac{1}{Pos} \sum_{i \in Pos} I[p_i \geq \mu] = \frac{TP(\mu)}{Pos}$$

- ▶ $FPR(\mu)$ (False Positive Rate):


$$FPR(\mu) = \frac{1}{Neg} \sum_{i \in Neg} I[p_i \geq \mu] = \frac{FP(\mu)}{Neg}$$

ROC кривая



ROC AUC


- ▶ ROC curves can be compared using area under the ROC curve (ROC AUC)
- ▶ ROC AUC $\in [0, 1]$ range
- ▶ ROC AUC = 0.5 means random guessing
- ▶ ROC AUC = 1 means ideal classification
- ▶ ROC AUC = 0 also means ideal classification, but for opposite labels 😊



Img: <https://glassboxmedicine.com/2019/02/23/measuring-performance-auc-auoc/>

Обсуждение

- ▶ В специализированном случае регрессий с бинарным выходом, мы можем использовать ROC кривую, как меру качества регрессии.




- ▶ Идеальное качество логистической регрессии достигается в случае ROC AUC = 1.

Распределение Манна-Уитни

- ▶ AUC следует статистике Манна-Уитни

$$AUC \sim \frac{U}{Pos \cdot Neg}$$




- ▶ Уже при небольших n статистика хорошо описывается Нормальным распределением.

Mason, S. et al. "Areas beneath the relative operating characteristics (ROC) <...>". Quarterly Journal of the Royal Meteorological Society. 128 (584): 2145–2166.

Реальные распределения

- ▶ Флуктуации и близость к ведут к проблемам в использовании распределения Манна-Уитни для построения интервалов.
- ▶ Необходимо использовать приближённые методы (см. семинар).



<https://dyakonov.org/2017/07/28/auc-roc-площадь-под-кривой-ошибок/>

Заклучение

- ▶ При решении задачи классификации можно использовать ROC-кривую как характеристику качества для логрегрессии.

Index name	Notation	Definition	Interpretations*
Area under the curve	AUC	$\int_0^1 \text{ROC}(t) dt$	(i) $P[Y_D > Y_{\bar{D}}]$ (ii) Average TPF across all possible FPF
Specific ROC point	$\text{ROC}(t_0)$	$\text{ROC}(t_0)$	$P[Y_D > q]$
Partial area under the curve	$\text{pAUC}(t_0)$	$\int_0^{t_0} \text{ROC}(t) dt$	(i) $t_0 P[Y_D > Y_{\bar{D}} Y_{\bar{D}} > q]$ (ii) Average TPF across $\text{FPF} \in (0, t_0)$
Symmetry point	Sym	$\text{ROC}(\text{Sym}) = \text{Sym}$	Sensitivity = specificity
Kolmogorov–Smirnov	KS	$\sup \text{ROC}(t) - t $	$\max S_D(c) - S_{\bar{D}}(c) $

* $q = 1 - t_0$ quantile for $Y_{\bar{D}}$

Выбор модели



All models are wrong, but some are useful

George Box

Выбор модели

Бритва Оккама — не надо “плодить” сущности. Много переменных приводят к большой дисперсии прогноза, но маленькому смещению, и наоборот.

При выборе подходящей модели возникают две задачи:

1. выбор целевой функции для характеристики качества используемой модели;
2. поиск оптимальной модели согласно выбранному критерию качества.

Критерии выбора модели

В принципе, в статистике нет ответа, как ”правильно” выбирать модель.

- › Зачем нужна модель?
- › Что она должна делать?
- › С какой скоростью она должна работать?

Вложенные модели

- ▶ Если модель A является частным случаем модели B , то есть, A можно получить из B , наложив на параметры некоторые ограничения (или сделав замену переменных), то говорят, что модель **A вложена в модель B** .

Очень приближённо, мы можем сравнить две девиансы с помощью теста Вальда:

$$W = \frac{D(R) - D(F)}{\hat{\phi}} \sim \chi^2_{df_R - df_F}$$

В принципе, в анализе мы можем использовать X^2 Пирсона.

Ср-Маллоу статистика

$$C_p(M) = \frac{SSE(M)}{\hat{\sigma}^2} - n + 2p(M).$$

- › $\hat{\sigma}^2 = \frac{SSE(F)}{df_F}$ - лучшая оценка $\hat{\sigma}^2$, которая у нас есть (из самой сложной модели с максимальным набором регрессоров);
- › $SSE(M) = ||Y - \hat{Y}_M||^2$ - сумма квадратов остатков в модели M .
- › $p(M)$ - количество предикторов модели (или количество степеней свободы, которое забираем модель).
- › Мотивирована разложением смещения-вариации.

AIC (Akaike information criterion):

$$AIC(S) = -2\ell(M) + 2p(M)$$

где $\ell(M) = \ell_M(\hat{\beta})$ — логарифм правдоподобия модели, где в качестве неизвестных параметров были подставлены их оценки, полученные с помощью максимизации $\ell_M(\beta)$.

В линейной регрессии в случае нормальных ошибок (шум берется равным оценке, полученной по полной модели) минимизация AIC эквивалента минимизации C_p .

BIC

BIC (Bayesian information criterion):

$$BIC(S) = -2\ell(M) + 2p(M) \log(n).$$

Этот функционал имеет байесовскую интерпретацию.

- › Пусть $\mathcal{S} = \{S_1, \dots, S_m\}$ — множество возможных моделей.
- › Допустим, что априорное распределение имеет вид $\mathbb{P}(S_j) = 1/m$.
- › Также предположим, что параметры внутри каждой модели имеют некоторое “гладкое” априорное распределение.
- › Можно показать, что апостериорная вероятность модели примерно равна

$$\mathbb{P}(S_j | \text{выборка}) \approx \frac{\exp(BIC(S_j))}{\sum_{r=1}^m \exp(BIC(S_r))}.$$

Оценка риска с помощью кросс-проверки (cross-validation; leave-one-out):

$$\hat{R}_{CV}(M) = \sum_{i=1}^n (\hat{Y}_{(i)} - Y_i)^2,$$

где $\hat{Y}_{(i)}$ — предсказание значения Y_i , полученное по модели, параметры которой оценены на обучающей выборке без i входа.

TABLE 13.2. Model Selection Indices for Non-Nested Models

Equation No.	Index	Rationale	Measure of model complexity	Pros	Cons
T15	$AIC = f + 2k$	Selects the model that had least expected discrepancy from the true model.	Number of parameters.	Easy to calculate. Performs well at large sample sizes.	Tends to select too complex models. Bad in recovering true model at small sample N .
T16	$CAIC = f + [1 + \ln(N)]k$	Selects the model that had least expected discrepancy from the true model.	Number of parameters and sample size.	Easy to calculate. Performs better than AIC at small sample size and large number of parameters.	
T17	$BIC = f + k \ln(N)$	Selects the model that is most likely to have generated the data in the Bayesian sense.	Number of parameters and sample size.	Easy to calculate. Performs well under large sample size.	Tends to select a model with too few parameters. Bad in recovering true model at small N .
T18	$CV = -\ln \int (y_{val} \hat{\theta}_{cal})$	Selects the model that has more generalizability to the sample from the population.	Complexity penalty is implicit.	Easy to calculate. More consistent with the implication of generalizability.	Requires sample split. Estimates are often unreliable, especially for small sample size.
T19	$ECVI = f + \frac{2k}{N}$	Expected value of CV.	Number of parameters and sample size.	Can be calculated using one sample. More consistent with the implication of generalizability.	Assumes multivariate normality.
T20	$BMS = \ln \int_{\Theta} f(y \theta) \pi(\theta) d\theta$	Selects the model with the highest mean likelihood of the data over the parameter space.	Number of parameters, sample size, and functional form of a model.	Includes more accurate measure on model complexity. Leads to more accurate model selection.	Computational burden. Hard to specify and calculate for most SEM models.

Note. AIC, Akaike information criterion; BIC, Bayesian information criterion; CV, cross-validation index; BMS, Bayesian model selection; f , minimized discrepancy function; k , the number of free parameters of the model; N , sample size; $\ln$, natural logarithm; y_{val} , the validation sample; y_{cal} , the calibration sample; $\hat{\theta}_{cal}$, the parameter values estimated by the calibration sample; $\pi(\theta)$, the prior density of the parameters; Θ , the parameter space.

(ed. by Rick Hoyle) Handbook of Structural Equation Modeling

Заклучение

- ▶ При переходе к обобщённым линейным моделям некоторые диагностики должны быть изменены.
- ▶ На основе этих диагностик можно делать выводы о качестве моделей.