

Прикладная статистика

Кроссвалидация

Денис Деркач

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2026

В этой лекции

- ▶ Как сравнить две модели?
- ▶ Какие тесты можно использовать при этом?

Мотивация



Вопросы про модель

- ▶ Как мы оцениваем качество модели?
 - Разделим на тренировочную и валидационную выборки.
 - Тренируемся на первой.
 - Валидируемся на второй.
 - Получаем ответ.

<https://arxiv.org/abs/1811.12808>

Качество и генерализация

- ▶ Чего мы хотим от процедуры?
 - оценить эффективность обобщения или насколько хороша модель на неизвестных данных;
 - найти гиперпараметры;
 - найти «лучшую модель» с «лучшими» гиперпараметрами.
- ▶ Несмещённость оценки качества
 - не нужна, если производится оценка качества модели и смещение одинаково для всех моделей.

Вывод


- ▶ Тип оценки качества модели зависит от цели исследования.
- ▶ Некоторыми смещениями можно пренебречь.

Стандартные методы оценки качества




Стратификация

- ▶ Разбиение нарушает предположение о независимости событий, что может привести к проблемам при оценке качества.
- ▶ Необходимо семплировать равномерно по классам.




https://github.com/rasbt/pattern_classification/blob/master/data_viz/model-evaluation-articles/iris-random-dist.ipynb

Валидация по отложенной выборке




1. Разбить на тренировочный и тестовый семпл.

Валидация по отложенной выборке




1. Разбить на тренировочный и тестовый семпл.
2. Натренировать модель с некоторыми фиксированными гиперпараметрами.

Валидация по отложенной выборке



1. Разбить на тренировочный и тестовый семпл.
2. Натренировать модель с некоторыми фиксированными гиперпараметрами.
3. Проверить качество на тестовом семпле.

Валидация по отложенной выборке




1. Разбить на тренировочный и тестовый семпл.
2. Натренировать модель с некоторыми фиксированными гиперпараметрами.
3. Проверить качество на тестовом семпле.

Проблемы разбиения

Проблема малых датасетов:

- ▶ Каждое семплирование может показывать разные выборки.
- ▶ Даёт случайное смещение оценки качества.




Пессимистическое смещение

- ▶ Тренировка и оценка на меньшем семпле ведут к большей дисперсии и (возможно) худшему качеству.
- ▶ Неравномерное семплирование классов может неправильно сместить качество.
 - Может быть проблемой, при выборе лучшей модели.
- ▶ Ненасыщенная модель может иметь смещение в оценке.

Монте-Карло Валидация



Идея:

- ▶ использовать много случайных разбиений;
- ▶ оценивать метрику качества, как среднюю по разбиениям.



Монте-Карло Валидация

- ▶ Выборка 150 событий.
 - Делим 50/50 со стратификацией,
 - Делим 90/10 со стратификацией.
- ▶ Повторяем 50 раз. Измеряем качество.
- ▶ Во втором случае Ассурасу чуть выше, но разброс сильно выше.



Out-Of-Bag Бутстреп

- ▶ Используем бутстреп-выборки для обучения.
- ▶ Оставшиеся события для валидации.
- ▶ Пессимистическое смещение в простом случае.




.632 оценка

- ▶ Вероятность быть выбранным при большом количестве семплов.

$$P(\text{chosen}) = 1 - \left(1 - \frac{1}{n}\right)^n \approx 0.632$$

- ▶ То есть мы оцениваем качество на 0.632 общей выборки.



This work by Sebastian Raschka is licensed under a Creative Commons Attribution 4.0 International License.

.632 оценка

- ▶ Подмешаем оптимистического смещения:

$$ACC_{boot} = \frac{1}{b} \sum_{i=1}^b (0.632 \cdot ACC_{h,i} + 0.368 \cdot ACC_{r,i})$$

где h – оценка качества на всём семпле при тренировке на всём семпле, а r – оценка в ООВ бутстрепе.

- ▶ Таким образом мы получим примерно несмещённую оценку качества.

ω -бутстреп

- ▶ Оценим реальный вес бутстрепа через ω :

$$ACC_{\text{boot}} = \frac{1}{b} \sum_{i=1}^b (\omega \cdot ACC_{h,i} + (1 - \omega) \cdot ACC_{r,i})$$

- ▶ для:
$$\omega = \frac{0.632}{1 - 0.368 \times R}$$

- ▶ где
$$R = \frac{(-1) \times (ACC_{h,i} - ACC_{r,i})}{\gamma - (1 - ACC_{h,i})}$$

γ – лосс в случае случайного перемешивания.

Вывод


- ▶ Стандартные оценки качества имеют проблемы со смещением.
- ▶ Бутстреп можно починить эмпирическими методами.

Кросс-валидация




K-Fold

- Разбиение на несколько подвыборок (фолдов)



Кроссвалидация и отложенная выборка


- ▶ Отложенная выборка – половина 2-fold кросс-валидации.
- ▶ При увеличении k растёт дисперсия.
- ▶ Нельзя построить оценку через дисперсию общей оценки.



<http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.9.3582>

Leave-one-out cross-validation

- ▶ Можем разбить на n подвыборок.
- ▶ Сделать n моделей и валидировать на одном событии.
- ▶ Как и во всей кросс-валидации нет универсальной оценки дисперсии.
- ▶ Малое смещение, большая дисперсия.



This work by Sebastian Raschka is licensed under a Creative Commons Attribution 4.0 International License.

k-fold и bias-variance decomposition

При увеличении k :

- ▶ Снижается смещение оценок (более точно)
- ▶ Разброс выше (коррелированные семплы)
- ▶ Большие затраты на подсчёт.
- ▶ В случае маленьких наборов, дисперсия также может повышаться при маленьких k .

Выбор гиперпараметров

Два популярных метода:

- ▶ Три отложенные выборки.
 - Хорошо, но получается смещённая оценка.
- ▶ K-fold кросс-валидация:
 - дорого для большого k .
 - при росте k может вмешаться корреляция между результатами, таким образом рост ошибки первого рода.

Вывод

- ▶ Кросс-валидация позволяет получить почти несмещённую оценку качества (при больших k).
- ▶ Выбор модели затруднён из-за:
 - Высокой стоимости.
 - Сильной корреляции между моделями.

Статистические тесты



Z-тест

$$z = \frac{ACC_1 - ACC_2}{\sqrt{2\sigma^2}} = \frac{ACC_1 - ACC_2}{\sqrt{2 \cdot ACC_{1,2}(1 - ACC_{1,2})/n}},$$

- ▶ Предполагаем, что метрики распределены по гауссу.
- ▶ Считаем средневзвешенное от $ACC_{1,2}$.
- ▶ Строим статистику и тестируем гипотезы.

Проблема

- ▶ В реальной жизни слишком строгая аппроксимация.

Тест МакНемара

- ▶ Сравниваем два классификатора

$$\chi^2 = \frac{(|B - C| - 1)^2}{B + C}$$

- ▶ Получаем chi2 распределение.
- ▶ Хорошо работает при большой выборке ($B, C > 50$)

		Model 2 correct	Model 2 wrong
Model 1	correct	A	B
	wrong	C	D



This work by Sebastian Raschka is licensed under a Creative Commons Attribution 4.0 International License.

Точное p-значение и биномиальный тест

$$p = 2 \sum_{i=\max(B,C)}^n \binom{n}{i} 0.5^i (1 - 0.5)^{n-i}$$

Для $n = A + B$ при небольших A и B можем подсчитать точное p-значение.

Дополняет тест МакНемара в малых значениях.

5x2 Тест Дитриха

Берём 5-fold кросс-валидацию. Для каждого фолда по тренировочной А и тестовой В выборкам:

$$ACC_A = ACC_{A,C_1} - ACC_{A,C_2}$$

$$ACC_B = ACC_{B,C_1} - ACC_{B,C_2}$$

Строим:

$$s^2 = (ACC_A - ACC_{avg})^2 + (ACC_B - ACC_{avg}^2)^2$$

5x2 Тест Дитриха и Алпайдина

- ▶ Статистики:

$$t = \frac{ACC_{A,1}}{\sqrt{(1/5) \sum_{i=1}^5 s_i^2}} \sim t_5$$

$$f = \frac{\sum_{i=1}^5 \sum_{j=1}^2 (ACC_{i,j})^2}{2 \sum_{i=1}^5 s_i^2} \sim F(10,5)$$

Множественное сравнение

Идея:

- ▶ сравниваем все классификаторы:

$$H_0 : ACC_1 = ACC_2 = \dots = ACC_M.$$

- ▶ если тест отклоняет нулевую гипотезу, используем апостериорный тест (например, МакНемара).

Q-тест Кохрана

$$Q = (M - 1) \frac{M \sum_{i=1}^M G_i^2 - T^2}{MT - \sum_{j=1}^n M_j^2}$$

Где M_j -- количество правильно классифицировавших событие j классификаторов, T -- количество правильных ответов всего, G_i -- количество правильных событий в каждом классификаторе.


$$Q \sim \chi_{M-1}^2$$

F-тест

Используем подход дисперсионного анализа, но с метрикой качества (предполагая, что она распределена нормально):


$$F = \frac{MSA}{MSB} \sim F(m - 1; (m - 1)n).$$

Вложенная кроссвалидация



Вывод

- ▶ Большое количество статистических тестов позволяют сравнивать 2 классификатора.
- ▶ Для быстрого сравнения нескольких необходимо использовать аналог ANOVA и апостериорные тесты.
 - Коррекции на множественное тестирование!



Выводы

- ▶ Необходимо проверять используемые методики на смещение и дисперсию.
- ▶ Для каждого типа задачи есть свой подход, контролирующий эти величины.