

Прикладная статистика

Непараметрические модели

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции


- ▶ Что делать, если нет модели?
- ▶ Оценки плотности
- ▶ Разложение bias-variance
- ▶ Кросс-валидационная оценка функции риска
- ▶ Ядерное сглаживание
- ▶ Оценка Надарая-Ватсона.

Постановка задачи



Мотивация

- ▶ Модель регрессии не всегда доступна:
 - данные слишком сложные;
 - теоретическая модель заведомо плохо описывает данные.
- ▶ Хотим построить надёжную модель для интерполяции, используя существующие данные как модель.



Непараметрическая регрессия

- ▶ Для n наблюдений: $(X_1, Y_1) \dots (X_n, Y_n)$, сгенерированных из совместной плотности $p(x, y)$. Модель:

$$Y_i = r(X_i) + \varepsilon_i, \varepsilon_i - i.i.d, \mathbb{E}\varepsilon_i = 0, \text{Var}\varepsilon_i = \sigma^2.$$

- ▶ Необходимо построить оценку функции регрессии:

$$r(x) = \mathbb{E}(Y|X = x) = \int yp(y|x)dy = \frac{\int yp(y, x)dy}{p(x)}.$$

.

http://faculty.washington.edu/yenchic/nonparametrics_list.html

Оценка плотности вероятности

Выборка: $X_1, \dots, X_n \sim F$.

F - абсолютно непрерывная функция распределения с неизвестной плотностью p . Необходимо оценить p в точке x , т.е. построить

$$\hat{p}(x) = \hat{p}_n(x; X_1, \dots, X_n).$$

Задача: найти способ построения $\hat{p}$.

<https://www.amazon.com/Pattern-Classification-Pt-1-Richard-Duda/dp/0471056693>

Порождающая модель

Задача регрессии (дискриминативная)

- › learn $\mathbb{P}(y|x)$
- › Directly characterizes the decision boundary between classes only
- › Examples: Logistic Regression, SVM, etc

Задача восстановления плотности (генеративная)


- › learn $\mathbb{P}(x|y)$ (and eventually $\mathbb{P}(y, x)$)
- › Characterize how data is generated (distribution of individual class)
- › Examples: Naive Bayes, HMM, etc.

<https://ai.stanford.edu/~ang/papers/nips01-discriminativegenerative.pdf>

Гистограммы



Построение гистограммы



- ▶ Для выборки $X_1, \dots, X_n \in (a; b]$.
- ▶ Поделим интервал на M равных частей Δ_i длины $h = \frac{b-a}{M}$:





$$\Delta_i = [a + ih, a + (i + 1)h), i = 0, 1, \dots, M - 1]$$

- ▶ Тогда оценка плотности:

$$\hat{p}_n(x) = \begin{cases} \frac{\nu_0}{nh}, & x \in \Delta_0, \\ \dots & \\ \frac{\nu_{M-1}}{nh}, & x \in \Delta_{M-1}; \end{cases} = \frac{1}{nh} \sum_{i=0}^{M-1} \nu_i \mathbb{I}\{x \in \Delta_i\}$$

где ν_i -- число элементов выборки, попавших в Δ_i .

Зависимость от ширины интервала



Точечная оценка плотности: идея

- ▶ Вероятность, что событие произойдёт в регионе R :

$$P = \int_R p(x') dx'$$

- ▶ Для n событий, вероятность k попаданий:

$$P(k) = \binom{n}{k} P^k (1 - P)^{n-k}$$

$$\mathbb{E}(k/n) = P$$

$$\mathbb{V}ar(k/n) = \frac{P(1 - P)}{n}$$

Точечная оценка плотности: идея

- ▶ Вероятность, что событие произойдёт в регионе R :

$$P = \int_R p(x') dx'$$

- ▶ Для хорошей оценки (при объёме R равном V):

$$p(x) \simeq \frac{k/n}{V}$$

- R **достаточно маленькое**, чтобы $p(x) \approx \text{const}$.
- R **достаточно большое**, чтобы k было большим.

Точечная оценка плотности: идея

- ▶ Можем выбрать последовательность отрезков R_i с объёмом V_i и количеством событий k_i :

$$\hat{p}(x) = \frac{k_n/n}{V_n}.$$

- R **достаточно маленькое**, чтобы $p(x) \approx \text{const}$.
- R **достаточно большое**, чтобы k было большим.
- ▶ Идеи:
 - фиксировать V_n и оценивать k_n ;
 - фиксировать k_n и оценивать V_n .

Смещение оценки

Для $x_0 \in \Delta_j$

$$\begin{aligned} bias(x_0) &= \mathbb{E}_p \hat{p}_n(x_0) - p(x_0) = \frac{1}{h} \int_{\Delta_j} p(x) dx - \frac{1}{h} \int_{\Delta_j} p(x_0) dx = \\ &= \frac{1}{h} \int_{\Delta_j} (p(x) - p(x_0)) dx \approx \frac{1}{h} \int_{\Delta_j} p'(x_0)(x - x_0) dx \approx \\ &\approx p'(x_0) \left[a + \left(j + \frac{1}{2} \right) h - x_0 \right] \end{aligned}$$

Дисперсия оценки

Для $x_0 \in \Delta_j$

$$\begin{aligned}\mathbb{V}ar_p \hat{p}_n(x_0) &= \mathbb{V}ar_p \frac{\nu_j}{nh} = \frac{1}{(nh)^2} \mathbb{V}ar_p \nu_j = \\ &= \frac{1}{(nh)^2} n \int_{\Delta_j} p(x) dx (1 - \int_{\Delta_j} p(x) dx) \approx \frac{1}{nh^2} \int_{\Delta_j} p(x) dx\end{aligned}$$

Есть две величины, характеризующие точность оценки в x_0 .

MSE

$$\begin{aligned}MSE(\hat{p}_n, p; x_0) &= \mathbb{E}_p[(\hat{p}_n(x_0) - p(x_0))^2] = \\&= [\mathbb{E}_p \hat{p}_n(x_0) - p(x_0)]^2 + \mathbb{E}_p[\hat{p}_n(x_0) - \mathbb{E}_p \hat{p}_n(x_0)]^2 = \\&= bias^2(x_0) + \text{Var}_p \hat{p}_n(x_0)\end{aligned}$$


Таким образом, оценивая смещение и дисперсию, мы оцениваем MSE.

MSE: пример

$$f(x) = \frac{2}{3} \left[\left(\frac{x}{2} + 1 \right) I\{x \in [-2, 0)\} + (1 - x) I\{x \in [0, 1)\} \right]$$

Для $x_0 = 0.5$

Оптимальные точки по дисперсии и смещению **не совпадают.**




Mean Integrated Squared Error

Проинтегрируем по всем x :

$$MISE(\hat{p}_n, p) = \mathbb{E}_p \left[\int_{\mathbb{R}} (\hat{p}_n(x) - p(x))^2 dx \right]$$

Метрика может быть использована для подбора оптимального h^* .

Сходимость по $MISE$



Интегральное смещение

$$p'(x_0)[a + (j + \frac{1}{2})h - x_0]$$

$$\begin{aligned} \int_a^b bias^2(x_0) dx_0 &= \sum_{j=0}^{N-1} \int_{\Delta_j} bias^2(x_0) dx_0 = \\ &= \sum_{j=0}^{N-1} \int_{\Delta_j} [p'(x_0)]^2 [a + (j + \frac{1}{2})h - x_0]^2 dx_0 \approx \\ &\approx \sum_{j=0}^{N-1} [p'(a + (j + \frac{1}{2})h)]^2 \int_{\Delta_j} (a + (j + \frac{1}{2})h - x_0)^2 dx_0 \\ &= \sum_{j=0}^{N-1} [p'(a + (j + \frac{1}{2})h)]^2 \left(-\frac{(a + (j + \frac{1}{2})h - x_0)^3}{3} \right) \Big|_{\Delta_j} \approx \\ &\approx \left(\int_a^b [p'(x)]^2 dx \right) \frac{h^2}{12}. \end{aligned}$$

Интегральная дисперсия

$$\frac{1}{nh^2} \int_{\Delta_j} p(x) dx$$

$$\begin{aligned} \int_a^b \mathbb{V}ar_{\hat{p}_n}(x_0) dx_0 &= \sum_{j=0}^{N-1} \left(\frac{1}{nh^2} \int_{\Delta_j} p(x) dx \right) h = \\ &= \frac{1}{nh} \int_a^b p(x) dx = \frac{1}{nh} \end{aligned}$$

MISE для гистограмм

$$MISE(\hat{p}_n, p) = \underbrace{\left(\int_{\mathbb{R}} [p'(x)]^2 dx \right)}_{\text{Bias}} \frac{h^2}{12} + \underbrace{\frac{1}{nh}}_{\text{Variance}}$$

Bias

Variance

Bias-variance tradeoff:

Для достижения **оптимального смещения** необходимо уменьшать h .

Для достижения **оптимальной дисперсии** необходимо увеличивать h .

Оптимальное сглаживание

Можем найти минимум MISE:

$$h^* = \frac{1}{n^{\frac{1}{3}}} \left(\frac{6}{\int_{\mathbb{R}} [p'(x)]^2 dx} \right)^{\frac{1}{3}}$$





При этом

$$MISE(\hat{p}_n, p) \approx \frac{C}{n^{\frac{2}{3}}}, \text{ где } C = \left(\frac{3}{4} \right)^{\frac{2}{3}} \left(\int_{\mathbb{R}} [p'(x)]^2 dx \right)^{\frac{1}{3}}$$

При использовании гистограммы с оптимальным h^* MISE убывает как $n^{-2/3}$.

Поиск оптимальной ширины окна

- ▶ Гистограммы – простейший метод оценки плотности.
- ▶ Имеют определённые гарантии сходимости.
- ▶ Страдают от проблем с нефиксированной левой границей.



Поиск оптимального сглаживания



Integrated Squared Error

- ▶ Необходимо избавиться от зависимости от $p(x)$.
- ▶ Уберём усреднение в MISE:

Не зависит от h

$$\mathcal{J}(h) = \int_{\mathbb{R}} (\hat{p}_n(x) - p(x))^2 dx = \int_{\mathbb{R}} \hat{p}_n(x)^2 dx - 2 \int_{\mathbb{R}} \hat{p}_n(x) p(x) dx + \int_{\mathbb{R}} p(x)^2 dx$$

↓
Можно подсчитать
в данных

↓
Усреднение оценки по настоящему распределению.

Усреднение оценки $\hat{p}(x)$

- ▶ Получаем:

$$\int \hat{p}_n(x) p(x) dx = \mathbb{E}_x \hat{p}_n.$$

- ▶ Оценим матожидание кросс-валидацией Leave-One-Out:

$$\widehat{\mathbb{E}_x \hat{p}_n} = \frac{1}{n} \sum \hat{p}_{n,(-i)}(X_i),$$

где $\hat{p}_{(-i)}$ - оценка по выборке без i -го наблюдения.

Оценка ISE

- ▶ Итоговая оценка, которую можно минимизировать для получения h_{cv} :

$$\hat{\mathcal{J}}(h) = \int_{\mathbb{R}} [\hat{p}_n(x)]^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{p}_{(-i)}(X_i)$$

- ▶ При этом


$$\mathbb{E} \hat{\mathcal{J}}(h) \approx \mathbb{E} \mathcal{J}(h)$$

- ▶ Для гистограмм:

$$\hat{\mathcal{J}}(h) = \frac{2}{(n-1)h} - \frac{n+1}{(h-1)h} \sum_{i=1}^M \left(\frac{\nu_j}{n} \right)^2$$

Оценка ISE

- ▶ Поведение в реальных данных.
- ▶ Вместо неизвестного MISE можно минимизировать ISE и найти оптимальное h_{cv} , которое будет недалеко от h^* .



Поиск оптимальной ширины окна

- ▶ Кросс-валидационная оценка позволяет использовать данные для поиска оптимального размера окна.
- ▶ Оценка основана на оптимизации ISE.
- ▶ Другие оценки основаны на оптимизации MISE, но, зачастую, показывают близкий результат на конечных выборках.

Метод ядерного сглаживания




Ядра

Ядро - функция K такая, что

$$K(x) \geq 0, \int_{\mathbb{R}} K(x) dx = 1, \int_{\mathbb{R}} x K(x) dx = 0, \sigma_K^2 \equiv \int_{\mathbb{R}} x^2 K(x) dx$$

Available Kernels



◀ $K(x) = \frac{1}{2}\mathbb{I}\{|x| < 1\}$ — прямоугольное ядро

◀ $K(x) = (1 - |x|)\mathbb{I}\{|x| < 1\}$ — треугольное ядро

◀ $K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$ — Гауссовское ядро


◀ $K(x) = \frac{3}{4}(1 - x^2)\mathbb{I}\{|x| < 1\}$ — ядро Епанечникова

Окно Парцена(–Розенблатта)

$$K(x) = \begin{cases} 1, & |x - h| < h/2, \\ 0, & \text{otherwise.} \end{cases}$$

- ▶ Специальная форма ядра, популярная в машинном обучении.
- ▶ Сейчас обычно заменяется на более гладкие ядра.
- ▶ Название остаётся.

Метод ядерного сглаживания




- Ядерное сглаживание:

$$\hat{p}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right),$$

K – ядро, h – ширина ядра.

Метод ядерного сглаживания (ядро)







► Ядерное сглаживание:

$$\hat{p}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right),$$

K – ядро, h – ширина ядра.

Метод ядерного сглаживания (ширина окна)



- Ядерное сглаживание:

$$\hat{p}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right),$$

K – ядро, h – ширина ядра.

Выбор ширины

- ▶ Аналогично гистограммам, можем подсчитать смещение:

$$bias(x) = \mathbb{E}_p \hat{p}_n(x) - p(x) \frac{1}{2} \sigma_K^2 h^2 p''(x)$$

- ▶ Интегральную характеристику:

$$\int_{\mathbb{R}} (bias(x))^2 dx = \frac{1}{4} \sigma_K^4 h^4 \int_{\mathbb{R}} [p''(x)]^2 dx$$

- ▶ Дисперсию:

$$\int_{\mathbb{R}} \mathbb{V}ar_p \hat{p}_n(x) dx = \frac{1}{nh} \int_{\mathbb{R}} K^2(z) dz$$

MISE и скорость сходимости

$$MISE(\hat{p}_n, p) \approx \frac{1}{4}\sigma_K^4 h^4 \int_{\mathbb{R}} (p''(x))^2 dx + \frac{1}{nh} \int_{\mathbb{R}} (K(x))^2 dx$$

Для оптимального $h = h^*$:

$$h^* = \left(\frac{1}{n} \frac{\int_{\mathbb{R}} (K(x))^2 dx}{\left(\int_{\mathbb{R}} x^2 K(x) dx \right)^2 \left(\int_{\mathbb{R}} p''(x))^2 dx \right)} \right)^{\frac{1}{5}}$$

При использовании гистограммы с оптимальным h^* MISE убывает как $n^{-4/5}$. Значительно быстрее, чем гистограммы.


Точечная оценка плотности: идея

- ▶ Можем выбрать последовательность отрезков R_i с объёмом V_i и количеством событий k_i :

$$\hat{p}(x) = \frac{k_n/n}{V_n}.$$

- R **достаточно маленькое**, чтобы $p(x) \approx \text{const}$.
- R **достаточно большое**, чтобы k было большим.
- ▶ Идеи:
 - фиксировать V_n и оценивать k_n ;
 - фиксировать k_n и оценивать V_n .

KDE2KNN



- ▶ Из-за фиксированных ширин $\hat{p}(x)$ может флуктуировать.
- ▶ Можно использовать переменную ширину ядра, чтобы лучше покрывать ХВОСТЫ.

$$\hat{p}_{knn}(x) = \frac{k}{n} \frac{1}{V_d R_k(x)}$$

S. Raschka's blog

KDE MISE

- MISE:

$$MISE(\hat{p}_{knn}(x)) = \mathcal{O}\left(\frac{k^4}{n^4} + \frac{1}{k}\right)$$

- Для оптимального h^* :

$$MISE(\hat{p}_{knn}(x)) = \mathcal{O}(n^{-4/5})$$

Аналогично KDE.

Проклятие размерности

- ▶ Оптимальная сходимость в многомерном пространстве $O(n^{-\frac{4}{4+d}})$.
- ▶ Для одинаковой ошибки необходимо всё больше данных.

d	1	2	3	4	5	6	7	8	9
n	4	19	67	223	768	2790	10700	43700	187000

где d — размерность данных, n — необходимый объём выборки.

KDE и kNN как оценки плотности

- ▶ Эффективны при оценке малых размерностей.
- ▶ Контролируемая скорость сходимости для систематической ошибки или дисперсии, но общая скорость аналогична.
- ▶ Доступны смеси KDE и kNN.
- ▶ Чтобы ускорить сходимость, один раз можно попытаться найти сигнальные многообразия.
- ▶ Довольно сложно отобразить и сохранить модель в памяти.

Оценка Надарая-Ватсона



Непараметрическая регрессия

Пусть $\hat{p}_n(x)$ и $\hat{p}_n(x, y)$ — ядерные оценки плотностей по выборкам $\{X_1, \dots, X_n\}$ и $\{(X_1, Y_1), \dots, (X_n, Y_n)\}$ соответственно с ядром K . Тогда, если $\hat{p}_n(x) \neq 0$, то


$$\hat{r}_n(x) = \frac{\int_{\mathbb{R}} y \hat{p}_n(x, y) dy}{\hat{p}_n(x)}$$

Оценка Надарая-Ватсона

$$\hat{r}_n^{NW} = \sum_{i=1}^n w_i(x) Y_i, \text{ где } w_i = \frac{K(\frac{x-X_i}{h})}{\sum_{j=1}^n K(\frac{x-X_j}{h})}, K \text{ заданная ядерная}$$

функция, $X_i \sim f(x)$

Смещение из-за дизайна эксперимента




- Оценки сходимости для ISE:

$$ISE(\hat{p}) = \frac{h_n^4}{4} \left(\int x^2 K(x) dx \right)^2 \int \left(r''(x) + 2r'(x) \frac{f'(x)}{f(x)} \right)^2 dx \\ + \frac{\sigma^2 \int K^2(x) dx}{nh_n} \int \frac{1}{f(x)} dx + o(nh_n^{-1}) + o(h_n^4)$$

Оценка Надарая-Ватсона: пример

Gaussian Kernel



Способы решения проблем

- ▶ Неравномерный дизайн внутри границ:
 - Использовать kNN ядра.
- ▶ Граничные эффекты:
 - Использовать локальную полиномиальную регрессию.

Локальная линейная регрессия

- ▶ Подсчитаем веса:

$$w_i(x) = K \left(\frac{x_i - x}{h} \right).$$

- ▶ Построим сумму квадратов:

$$\sum w_i(x) (Y_i - a)^2.$$


- ▶ Решение:

$$\hat{r}_n(x) = \sum w_i(x) Y_i / \sum w_i(x).$$

- ▶ Локальная константа! Мы можем также найти полиномиальное решение.

Способы решения

Смещение на границах
уменьшилось



Заклучение

- ▶ Оценка Надарая-Ватсона позволяет строить регрессию в условиях сложных данных, когда теоретическая модель недоступна.
- ▶ Качество оценки сильно зависит от количества данных в условиях многомерных данных.
- ▶ Трубка погрешности для модели может иметь сложные интерпретации.
- ▶ KDE и KNN могут использоваться как порождающие модели.