

Прикладная статистика

Байесовская регрессия

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Некоторые результаты предыдущих лекций.
- ▶ Байесовская регрессия.
- ▶ Предсказания с использованием байесовской регрессии.

Напоминание



Линейная регрессия

- ▶ Для набора данных: $\{(x^{(i)}; y^{(i)})\}_{i=1}^N$.
- ▶ Линейная модель:

$$\hat{y} = w^T \psi(x).$$

- ▶ Функция потерь:

$$\mathcal{L}(y, t) = \frac{1}{2} (\hat{y} - y)^2.$$

Решение:

$$w = (\Psi^T \Psi)^{-1} \Psi^T y$$

Линейная регрессия с регуляризацией

- ▶ Для набора данных: $\{(x^{(i)}; y^{(i)})\}_{i=1}^N$.

- ▶ Линейная модель:

$$\hat{y} = w^T \psi(x).$$

- ▶ Функция потерь:

$$\mathcal{L}(y, t) = \frac{1}{2} (\hat{y} - y)^2.$$

- ▶ L2 регуляризация

$$R(w) = \frac{\lambda}{2} ||w||^2$$

Решение:

$$w = (\Psi^T \Psi + \lambda I)^{-1} \Psi y$$

ОМП для линейной регрессии

- ▶ В предположении гауссова шума в модели:

$$y|x \sim \mathcal{N}(w^T \psi(x), \sigma^2).$$


- ▶ Коэффициенты линейной регрессия в таком случае получаются с помощью ОМП:

$$\begin{aligned} \frac{1}{N} \sum \log p(y^{(i)} | x^{(i)}; w, b) &= \frac{1}{N} \sum \log \mathcal{N}(y^{(i)}; w^T \psi(x), \sigma^2) = \\ &= \frac{1}{N} \sum \log \left(\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(t^{(i)} - w^T \psi(x))^2}{2\sigma^2}\right) \right) = \\ &= \text{const} - \frac{1}{2N\sigma^2} \sum (t^{(i)} - w^T \psi(x))^2. \end{aligned}$$

Байесовский вывод

Функция правдоподобия

Априорное распределение


$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)}$$

Распределение данных

Можно подобрать такое априорное распределение $g(\theta)$, которое не выводит при умножении на $f(x|\theta)$, оставляет $f(\theta|X)$ в том же классе распределений.

Семейство $g(\theta)$ будем называть **сопряжённым** к $f(x|\theta)$.

Построение оценки

- ▶ ОМП определяет значения параметров, при которых наши данные наиболее вероятны.
- ▶ На самом деле, мы обычно задаёмся вопросом, какие значения параметров наиболее вероятны:

$$f(\theta|X) = f(X|\theta)g(\theta)/h(X)$$

где f , g и h – соответствующие функции распределения.

- ▶ **Оценка апостериорного максимума (МАР)** определяется как значение $\hat{\theta}_n$ параметра θ , которое максимизирует $f(\theta|X)$.

K. Murphy, Machine Learning: a Probabilistic Perspective

Связь с ОМП

- ▶ МАР и ОМП очевидно связаны:

$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)} = \prod \frac{f(x_i; \theta)g(\theta)}{h(x)} \sim c \prod f(x_i; \theta)g(\theta)$$

- ▶ Логарифмируем:

$$\log f(\theta|X) = \log(g(\theta)) + \sum \log(f(x_i|\theta)).$$

- ▶ Получается, что значение МАР оценки и значение ОМП совпадают с точностью до априорной оценки $\log(g(\theta))$.

Теорема Бернштейна-фон Мизеса

Для некоторого априорного распределения, выборки D_n из n элементов и регулярной модели, апостериорное распределение:

$$\mathcal{P}(p|D_n) \sim N(\theta^*; I^{-1}(\theta^*)), n \rightarrow \infty,$$

где θ^* - оценка максимального правдоподобия, а I – информация Фишера.

Означает ли это, что байесовская интерпретация проверяется частотной?
Не обязательно, но может натолкнуть нас на мысли 😊

Изи: G. Young, R.L. Smith Essentials of Statistical Inference (sec 9.12)
Не изи: Van der Vaart, Asymptotic Statistics (sec. 10.2)

Байесовский вывод на практике



Поиск параметров: мотивация

Дано: измерение $x \sim p_x(x|y)$.


Закон $x = f(y)$.

Найти: Апостериорное распределение
 $p_Y = p(y|x)$

Используя теорему Байеса

$$p(y|x) = \frac{p(x|y)p_Y(y)}{p_x(x)}$$


- Семплируем $Y \sim p_Y$, используя априорное знание для $Y \sim U[a, b]$.
- Взвешиваем с измерением.
- Проделываем операцию много раз.



Дополнительное измерение

Дано: измерения X, Z .
Закон $X = f(Y); Z = g(Y)$.
Найти: Распределение Y

- Семплируем $Y \sim p_Y$, используя априорное знание для $Y \sim U[a, b]$.
- Взвешиваем с **измерениями**.
- Прodelываем операцию много раз.




Проклятие размерности

Дано: измерения X, Z .

Закон $X = f_j(Y); j = 1, \dots, N$.

Найти: Распределение Y

- Можно использовать специальные преобразования пространства и или MCMC



Выводы

- ▶ Байесовский способ предоставляет возможность параметрического оценивания (мы знали!).
- ▶ Формально, мы можем исследовать таким образом любую функциональную зависимость.
- ▶ В случае задачи с большим количеством измерений, мы можем столкнуться со сложностями в прямой оценке.

Байесовская регрессия



Мотивация: линейная регрессия

$$y_n = \mathbf{w}^T \mathbf{x}_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \sigma^2), \quad n = 1, \dots, N$$
$$\mathbf{w} \sim p(\mathbf{w}).$$

- ▶ y_n – наблюдаемая **случайная** переменная
- ▶ w – неизвестный **фиксированная** переменная
- ▶ x_n – известная **фиксированная** переменная
- ▶ ε_n – неизвестная **случайная** переменная
- ▶ σ – известная **фиксированная** переменная

Байесовская линейная регрессия

$$y_n = \mathbf{w}^T \mathbf{x}_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \sigma^2), \quad n = 1, \dots, N$$

$$\mathbf{w} \sim p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; \mathbf{m}_0, \Sigma_0)$$


- ▶ y_n – наблюдаемая **случайная** переменная
- ▶ w – неизвестный **случайная** переменная
- ▶ x_n – известная **фиксированная** переменная
- ▶ ε_n – неизвестная **случайная** переменная
- ▶ σ – известная **фиксированная** переменная

Все априорные распределения – нормальные.


Многомерное нормальное распределение

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \underbrace{\frac{1}{(2\pi)^{D/2} \sqrt{\det \boldsymbol{\Sigma}}}}_Z \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$

- ▶ $\boldsymbol{\mu}$ – вектор средних;
- ▶ $\boldsymbol{\Sigma}$ – матрица ковариации;
- ▶ Z – нормировка.



$$\boldsymbol{\Sigma} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$



$$\boldsymbol{\Sigma} = \begin{pmatrix} 1 & 0.4 \\ 0.4 & 0.5 \end{pmatrix}$$

Доказательства: [T. Schon et al, Manipulating Multivariate Density](#)

Маргинализация нормального распределения

$$p(x_a) = \int p(x_a, x_b) dx_b$$


- ▶ Для нормального распределения, $x_{a,b} \in \mathbb{R}^{n_{a,b}}$:

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix}$$

- ▶ Маргинальное распределение $p(x_a)$ задаётся:

$$p(x_a) = \mathcal{N}(x_a; \boldsymbol{\mu}_a, \boldsymbol{\Sigma}_{aa}).$$

Маргинализация нормального распределения




Маргинальное

$p(x_a, x_b)$

$p(x_a)$

$p(x_b)$



Условное распределение

$$p(x_a|x_b) = \frac{p(x_a, x_b)}{p(x_b)}$$

- ▶ Для нормального распределения, $x_{a,b} \in \mathbb{R}^{n_{a,b}}$:

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix}$$


- ▶ Условное распределение $p(x_a)$ задаётся:

$$p(x_a|x_b) = \mathcal{N}(x_a; \mu_{a|b}, \Sigma_{a|b}),$$

$$\mu_{a|b} = \mu_a + \Sigma_{ab}\Sigma_{bb}^{-1}(x_b - \mu_b);$$

$$\Sigma_{a|b} = \Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba}.$$

Условное нормальное распределение



Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Аффинное цепное правило

$$p(x_a, x_b) = p(x_a|x_b)p(x_b)$$

- ▶ Для нормальных распределений, $x_{a,b} \in \mathbb{R}^{n_{a,b}}$:

$$p(x_a) = \mathcal{N}(x_a; \mu_a, \Sigma_a)$$

$$p(x_b|x_a) = \mathcal{N}(x_b; Mx_a + c, \Sigma_{b|a})$$

- ▶ Совместное распределение $p(x_a, x_b)$ задаётся:

$$p(x_a, x_b) = \mathcal{N}\left(\begin{bmatrix} x_a \\ x_b \end{bmatrix}; \begin{bmatrix} \mu_a \\ M\mu_a + c \end{bmatrix}, R\right),$$

$$R = \begin{bmatrix} \Sigma_a & \Sigma_a M^T \\ M\Sigma_a & \Sigma_{b|a} + M\Sigma_a M^T \end{bmatrix}.$$

Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

Цепное

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Байесовская линейная регрессия

$$y_n = \mathbf{w}^T \mathbf{x}_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \beta^{-1}), \beta = \sigma^{-2}, n = 1, \dots, N$$

$$\mathbf{w} \sim p(\mathbf{w}).$$

Вероятностная модель:

$p(y | \mathbf{w}) = \mathcal{N}(y; X\mathbf{w}, \beta^{-1}I_N)$, полученное правдоподобие;

$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; m_0, S_0)$, априорное распределение.

Найти:

$p(\mathbf{w}|y)$ – апостериорное распределение

Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

Цепное

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Цепное+условное

- ▶ Для нормальных распределений, $x_{a,b} \in \mathbb{R}^{n_{a,b}}$:

$$p(x_a) = \mathcal{N}(x_a; \mu_a, \Sigma_a)$$

$$p(x_b|x_a) = \mathcal{N}(x_b; Mx_a + c, \Sigma_{b|a})$$

- ▶ Условное распределение $p(x_a, |x_b)$ задаётся:

$$p(x_a|x_b) = \mathcal{N}(x_a; \mu_{a|b}, \Sigma_{a|b}),$$

$$\mu_{a|b} = \Sigma_{a|b} \left(\Sigma_a^{-1} \mu_a + M^T \Sigma_{b|a}^{-1} (x_b - c) \right);$$

$$\Sigma_{a|b} = \left(\Sigma_a^{-1} + M^T \Sigma_{b|a}^{-1} M \right)^{-1}.$$

Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

Цепное

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Цепное+условное

Байесовская линейная регрессия

$$y_n = \mathbf{w}^T x_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \beta^{-1}), \beta = \sigma^{-2}, n = 1, \dots, N$$

$$\mathbf{w} \sim p(\mathbf{w}).$$

Вероятностная модель:

$p(y | \mathbf{w}) = \mathcal{N}(y; X\mathbf{w}, \beta^{-1}I_N)$, полученное правдоподобие;

$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; m_0, S_0)$, априорное распределение.

Найти:

$p(\mathbf{w}|y)$ – апостериорное распределение

Решение:

Используем Цепное+условное для $x_a = \mathbf{w}$, $x_b = y$.

«Цепное + условное» переход

Вероятностная модель:

$$\begin{aligned}p(x_a|x_b) &= \mathcal{N}(x_a; \mu_{a|b}, \Sigma_{a|b}), \\ \mu_{a|b} &= \Sigma_{a|b} \left(\Sigma_a^{-1} \mu_a + M^T \Sigma_{b|a}^{-1} (x_b - c) \right); \\ \Sigma_{a|b} &= \left(\Sigma_a^{-1} + M^T \Sigma_{b|a}^{-1} M \right)^{-1}.\end{aligned}$$

для $x_a = w$, $x_b = y$:

$$\begin{aligned}p(\textcolor{red}{w}|y) &= \mathcal{N}(w; m_N, S_N). \\ m_N &= S_N(S_0^{-1}m_0 + \beta X^T y) \\ S_N^{-1} &= S_0^{-1} + \beta X^T X\end{aligned}$$

m_N - MAP оценка

m_N, S_N - при $N = 0$ априорное распределение

Пример: 1D регрессия

- ▶ Рассмотрим функцию:

$$f(x) = a_0 + a_1x, a_0 = -0,3, a_1 = 0,5$$

- ▶ Сгенерируем N точек: $x_n^T = (x_1, \dots, x_N)$, $\varepsilon \sim \mathcal{N}(0, \beta^{-1})$, $\beta = 5^2$ (считаем известным).

- ▶ Модель:


$$y_n = w^T x_n + \varepsilon_n = w_0 + w_1 x_n + \varepsilon_n.$$

- ▶ Априорное распределение:


$$p(\textcolor{red}{w}) = \mathcal{N}(w; (0,0)^T, \alpha^{-2}I_2), \alpha = 2.$$

Визуализация априорного распределения

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; (0,0)^T, \alpha^{-2}I_2), \alpha = 2.$$




Априорное распределение



Реализация априорного
распределения в
пространстве параметров

Визуализация апостериорного распределения

После первого измерения




$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \mathbf{S}_0)$$

$$p(y_1 | \mathbf{w}) = \mathcal{N}(y_1 | w_0 + w_1 x_1, \beta^{-1})$$

$$p(\mathbf{w} | y_1) = \mathcal{N}(\mathbf{w} | \mathbf{m}_1, \mathbf{S}_1),$$

$$\mathbf{m}_1 = \beta \mathbf{S}_1 \mathbf{X}^\top y_1,$$



$$\mathbf{S}_1 = (\alpha \mathbf{I}_2 + \beta \mathbf{X}^\top \mathbf{X})^{-1}.$$



апостериорные реализации

Визуализация апостериорного распределения

После второго измерения



$$p(\mathbf{w} | y_1) = \mathcal{N}(\mathbf{w} | \mathbf{m}_1, \mathbf{S}_1) \quad p(y_2 | \mathbf{w}) =$$

$$\mathcal{N}(y_2 | w_0 + w_1 x_2, \beta^{-1}) \quad p(\mathbf{w} | y_2) = \mathcal{N}(\mathbf{w} | \mathbf{m}_2, \mathbf{S}_2),$$



$$\mathbf{m}_2 = \beta \mathbf{S}_2 \mathbf{X}^T \mathbf{y},$$

$$\mathbf{S}_2 = (\alpha \mathbf{I}_2 + \beta \mathbf{X}^T \mathbf{X})^{-1}$$

апостериорные реализации

Визуализация апостериорного распределения

После тридцатого измерения



Апостериорные реализации:

- Сходятся к оригинальной модели.
- Лучше описывают центр.

Сопряжённые распределения

Вероятностная модель:

$p(y | \mathbf{w}) = \mathcal{N}(y; X\mathbf{w}, \beta^{-1}I_N)$, полученное правдоподобие;

$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; m_0, S_0)$, априорное распределение.

Результат:

$p(\mathbf{w}|y) = \mathcal{N}(\mathbf{w}; m_N, S_N)$, апостериорное распределение

- ▶ Мы использовали свойства сопряжённости нормального распределения:

$$\begin{array}{ccccc} \text{posterior} & & \text{likelihood} & & \text{prior} \\ \underbrace{p(\mathbf{w} | \mathbf{y})}_{\text{Gaussian}} & \propto & \underbrace{p(\mathbf{y} | \mathbf{w})}_{\text{Gaussian}} & \underbrace{p(\mathbf{w})}_{\text{Gaussian}} \end{array}$$

- ▶ В результате, при оценке параметров, мы получаем функцию правдоподобия, которую легко интегрировать.

MAP и регуляризация

- ▶ Поиск параметров с помощью оптимизации MAP:

$$\log f(w|y) = \log(g(w)) + \sum \log(f(y_i|w)).$$

- ▶ В нашем случае:

$$g(w) = \mathcal{N}(w; m_0, S_0);$$

$$\log g(w) = -\frac{1}{2}(w - m_0)S_0^{-1}(w - m_0) + \text{const}.$$

- ▶ Возьмём $m_0 = 0, S_0 = \alpha$:

$$g(w) = \frac{1}{2\alpha}w^2.$$

- ▶ Оптимизация в случае нормального априорного распределения с центром в 0 эквивалентна L2 регуляризации.

Поиск параметров

- ▶ Последовательный:
 - добавляем измерение за измерением;
 - **соблюдается** условие на гауссовость правдоподобия;
 - очень долго (но применяется, см. ниже).
- ▶ Пакетный (батч):
 - добавляем сразу много измерений;
 - правдоподобие может быть гауссово **приблизительно**;
 - быстрый поиск параметров.

Неизвестная β

Вероятностная модель:

$p(y | \mathbf{w}, \beta) = \mathcal{N}(y; X\mathbf{w}, \beta^{-1}I_N)$, полученное правдоподобие;

$p(\mathbf{w}, \beta) = \mathcal{N}(\mathbf{w}; m_0, S_0)\text{Gam}(\beta; a_0, b_0)$, априорное распределение.

Результат:

$p(\mathbf{w}, \beta | y) = \mathcal{N}(\mathbf{w}; m_N, S_N)\text{Gam}(\beta; a_N, b_N)$, апостериорное распределение

- ▶ Мы используем свойства сопряжённости нормального распределения и гамма-функции.

$$\underbrace{p(\mathbf{w}, \beta | \mathbf{y})}_{\text{Gauss-Gamma}} \propto \underbrace{p(\mathbf{y} | \mathbf{w}, \beta)}_{\text{Gauss}} \underbrace{p(\mathbf{w}, \beta)}_{\text{Gauss-Gamma}}$$

https://en.wikipedia.org/wiki/Normal-gamma_distribution

Поиск параметров

- ▶ Последовательный:
 - добавляем измерение за измерением;
 - **соблюдается** условие на гауссовость правдоподобия;
 - очень долго (но применяется, см. ниже).
- ▶ Пакетный (батч):
 - добавляем сразу много измерений;
 - правдоподобие может быть гауссово **приблизительно**;
 - быстрый поиск параметров.

Выводы

- ▶ Для получения байесовской регрессии используется предположение об априорном распределении параметров.
- ▶ Простейшая байесовская регрессия с нормальными априорными распределениями эквивалентна регуляризации.
- ▶ Для неизвестного шума необходимо использовать другое априорное распределение.
- ▶ Если использовать несопряжённое распределение, найти оптимум становится сложно.

Предсказания



Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

Цепное

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Цепное+условное

Маргинальное

Условное

$$p(x_a, x_b)$$

$$p(x_a)$$

Цепное

$$p(x_b|x_a)$$

$$p(x_b)$$

$$p(x_a|x_b)$$

Предсказание

Цепное+условное

Путь «Предсказание»

- ▶ Для нормальных распределений, $x_{a,b} \in \mathbb{R}^{n_{a,b}}$:

$$p(x_a) = \mathcal{N}(x_a; \mu_a, \Sigma_a)$$

$$p(x_b|x_a) = \mathcal{N}(x_b; Mx_a + c, \Sigma_{b|a})$$

- ▶ Условное распределение $p(x_a, |x_b)$ задаётся:

$$p(x_b) = \mathcal{N}(x_b; \mu_b, \Sigma_b),$$

$$\mu_b = M\mu_a + c;$$

$$\Sigma_b = \Sigma_{b|a} + M\Sigma_a M^T.$$

Предсказание распределения

- ▶ Для новой точки (y_*, x_*) :

$$p(y_* | \mathbf{w}) = \mathcal{N}(y_*; x_*^T \mathbf{w}, \beta^{-1}), \text{ правдоподобие}$$

$$p(w | y) = N(w; m_N, S_N) \text{ апостериорное распределение}$$

- ▶ Используя $p(x_b) = \mathcal{N}(x_b; \mu_b, \Sigma_b)$, $x_a = w$, $x_b = y_*$. Получаем:

$$p(y_* | y) = N(y_*; m_*, s_*)$$

$$m_* = x_*^T m_N$$

$$s_* = \beta^{-1} + x_*^T S_N x_*$$

Предсказание распределения

- ▶ Для новой точки (y_*, x_*) :

$$p(y_* | \mathbf{w}) = \mathcal{N}(y_*; x_*^T \mathbf{w}, \beta^{-1}), \text{ правдоподобие}$$

$$p(w | y) = N(w; m_N, S_N) \text{ апостериорное распределение}$$

- ▶ Используя $p(x_b) = \mathcal{N}(x_b; \mu_b, \Sigma_b)$, $x_a = w$, $x_b = y_*$. Получаем:


$$p(y_* | y) = N(y_*; m_*, s_*)$$

$$m_* = x_*^T m_N$$


$$s_* = \beta^{-1} + x_*^T S_N x_*$$

NB: для случая неизвестного β вместо нормального у нас появляется распределение t-распределение.


Пример



$N = 2$ observations



$N = 5$ observations



$N = 200$ observations

Используя предсказанное распределение в каждой точке, сравниваем **настоящую функцию**, **предсказание** и 68% регион.

Вывод

- ▶ Байесовская регрессия может быть использована для получения предсказаний в каждой точке.
- ▶ Основа предсказаний **байесовская**.
- ▶ На основании последовательного обучения и предсказаний значений можно построить линейный фильтр (фильтр Калмана).

Общий вывод

- ▶ В подходе байесовской регрессии учитывается распределение данных и используется MAP оценка параметров.
- ▶ В случае бесконечного количества данных, решение будет эквивалентно частотной.
- ▶ Переобучение имеет другие характеристики.