

Прикладная статистика

Ридж и Лассо

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Декомпозиция ошибки.
- ▶ Гребневая регрессия.
- ▶ Регрессия Лассо.
- ▶ Эластичная сеть.

Напоминание



Линейная регрессия

Погрешность предсказания

- ▶ Для оценки $\hat{f}$ и некоторой точки $(x_0; y_0)$ из набора:

$$\begin{aligned} PE(\hat{f}(x_0)) &= \mathbb{E} \left(\left(y_0 - \hat{f}(x_0) \right)^2 \right) = \\ &= \mathbb{E} \left(\left(y_0 - f(x_0) + f(x_0) - \hat{f}(x_0) \right)^2 \right) = \\ &= \mathbb{E} \left((y_0 - f(x_0))^2 \right) + \mathbb{E} \left((f(x_0) - \hat{f}(x_0))^2 \right) = \\ &= \sigma^2 + MSE \left(\hat{f}(x_0) \right). \end{aligned}$$

- ▶ Погрешность предсказания коррелируют со значением MSE .

Теорема Гаусса-Маркова

- ▶ Оценки метода наименьших квадратов оптимальны в классе **линейных несмещённых** оценок (LS is BLUE):

$$MSE\left(\hat{f}(x_0)\right) \geq MSE\left(\hat{f}^{LS}(x_0)\right)$$

- ▶ С учётом разложения

$$MSE\left(\hat{f}(x_0)\right) = \textbf{Bias}^2\left(\hat{f}(x_0)\right) + Var\left(\hat{f}(x_0)\right),$$

- ▶ Получаем

$$PE\left(\hat{f}^{LS}(x_0)\right) = \sigma^2 + \textbf{0} + Var\left(\hat{f}(x_0)\right).$$

Оценка среднего PE

- ▶ Оценим среднюю погрешность предсказания для всех точек набора:

$$PE(\hat{f}) = \frac{1}{n} \sum PE(\hat{f}(x_i)).$$

$$\begin{aligned} PE(\hat{f}) &= \sigma^2 + MSE(\hat{f}) = \\ &= \sigma^2 + \frac{1}{n} \sum Bias^2(\hat{f}(x_i)) + \frac{1}{n} \sum Var(\hat{f}(x_i)). \end{aligned}$$

- ▶ Показывает общую погрешность предсказания на имеющемся наборе.

Дисперсия МНК

- ▶ Для средней дисперсии:

$$\begin{aligned}\frac{1}{n} \sum \text{Var}(\hat{f}(x_i)) &= \frac{1}{n} \sum \text{Var}(x_i^T \hat{\beta}) = \\&= \frac{1}{n} \text{Tr}(\text{Var}(X\hat{\beta})) = \frac{1}{n} \text{Tr}(\text{Var}(X(X^T X)^{-1} X^T y)) = \\&= \frac{1}{n} \text{Tr}(h\sigma_\epsilon^2 I h) = \frac{\sigma_\epsilon^2}{n} \text{Tr}(X(X^T X)^{-1} X^T) = \frac{\sigma_\epsilon^2}{n} \text{Tr}(X^T X (X^T X)^{-1}) \\&= \frac{\sigma_\epsilon^2 p}{n}.\end{aligned}$$

Дисперсия МНК

- ▶ Оценим дисперсию в случае МНК:

$$\text{Var}(\hat{f}(x_0)) = \frac{\|h(x_0)\|^2}{n} \sigma_\epsilon^2,$$

где $h(x_0) = X(X^T X)^{-1} x_0$



- ▶ Для средней дисперсии:

$$\frac{1}{n} \sum \text{Var}(\hat{f}(x_i)) = \frac{p}{n} \sigma_\epsilon^2.$$

Оценка среднего PE для МНК

- Таким образом средняя погрешность:

$$PE(\hat{f}) = \sigma^2 + 0 + \frac{p}{n} \sigma^2.$$



Оценка среднего PE для МНК

- ▶ Таким образом средняя погрешность:

$$PE(\hat{f}) = \sigma^2 + \mathbf{0} + \frac{p}{n}\sigma^2.$$

- ▶ Ограничены классом линейных и несмещённых оценок для них:

$$MSE(\hat{f}) \geq MSE(\hat{f}^{LS}).$$

- ▶ Можем ли мы выйти из класса несмещённых оценок?
 - Снизим количество параметров?
 - Каким будет смещение?


Воспоминания: непараметрические оценки

Проинтегрируем по всем x :

$$MISE(\hat{p}_n, p) = \mathbb{E}_p \left[\int_{\mathbb{R}} (\hat{p}_n(x) - p(x))^2 dx \right]$$

Метрика может быть использована для подбора оптимального h^* .

Сходимость по $MISE$



Недостатки обычной линейной регрессии

- ▶ **Качество предсказания.** Мы увидели, что МНК не ведёт к оптимальному качеству предсказания. Мы можем снизить MSE за счёт игры между дисперсией и смещением снижением p .
- ▶ **Интерпретируемость.** Всегда проще рассказать только о наиболее важных предикторах. Линейная регрессия не даёт такой возможности.
- ▶ Плохая работа с переопределёнными системами ($p > n$).

С помощью снижения p мы можем решить эти недостатки.

Выводы

- ▶ Метод наименьших квадратов даёт несмещённую оценку.
- ▶ За счёт релаксирования требования несмещённости можно получить меньший MSE предсказания.

Гребневая регрессия



Гребневая (ридж) регрессия


- ▶ Добавляем дополнительное слагаемое в оценку параметров для $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$:

$$\begin{aligned}\hat{\beta}^{ridge} &= \operatorname{argmin}_{\beta \in \mathbb{R}^p} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{i=1}^n (y_i - x_i^T \beta)^2 = \\ &= \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2.\end{aligned}$$

- ▶ $\lambda \geq 0$ – свободный параметр:
 - Если $\lambda = 0$, получается обычная линейная регрессия.
 - Если $\lambda = \infty$, получается $\hat{\beta}^{ridge} = 0$.
 - Хотим сбалансировать λ .

Поведение коэффициентов регрессии

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ Две группы коэффициентов β : 20 маленьких и 10 больших.
- ▶ $\lambda = 25$
- ▶ Оценки для «больших» снижаются. «маленькие» перемешиваются.



Наблюдения

- ▶ Нулевой коэффициент не регуляризуется:

$$\hat{\beta}^{ridge} = \operatorname{argmin}_{\beta^0 \in \mathbb{R}^1, \beta \in \mathbb{R}^p} \|y - \beta_0 I - X\beta\|_2^2 + \lambda \|\beta\|_2^2.$$

Обычно мы считаем, что данные центрированы.

- ▶ В случае разных масштабов очень важно нормировать входные данные, иначе получается плохо контролируемое смещение.

Bias-Variance Trade-off

- ▶ Мы также можем выписать MSE для ридж оценки:



$$\begin{aligned}MSE(\hat{\beta}_r) &= E[(\hat{\beta}_r - \beta)^\top (\hat{\beta}_r - \beta)] = \text{Var}(\hat{\beta}_r) + [\text{Bias}(\hat{\beta}_r)]^2 \\&= \sigma^2 \text{tr}\{K(X^\top X)^{-1}K^\top\} + \beta^\top (K - I)^\top (K - I)\beta \\ \text{Var}(\hat{\beta}_r) &= \sigma^2 \text{tr}\{K(X^\top X)^{-1}K^\top\} \\ [\text{Bias}(\hat{\beta}_r)]^2 &= \beta^\top (K - I)^\top (K - I)\beta.\end{aligned}$$

Для $K = (X^\top X + \lambda I)^{-1}X^\top X$.

- ▶ Отсюда видно, что

$$\lim_{\lambda \rightarrow \infty} MSE(\hat{\beta}_r) = \beta^\top \beta$$


Bias-Variance Trade-off



При росте λ оценки становятся всё ближе к 0.


MSE

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ Две группы коэффициентов β : 20 маленьких и 10 больших.
- ▶ $\lambda \in [0; 25]$.




MSE для случайных коэффициентов

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ 30 коэффициентов β примерно одинакового масштаба.
- ▶ Ридж-регрессия всё равно даёт выигрыш (но для малых параметров).




Ридж регрессия для плохих регрессоров

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ 30 коэффициентов β : 10 значимых и 20 равных нулю.
- ▶ Ридж-регрессия всё равно даёт выигрыш (но для малых параметров).
- ▶ Здесь интересно, что оптимальный λ небольшой.




Ридж регрессия для плохих регрессоров

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ 30 коэффициентов β : 10 значимых и 20 равных нулю.
- ▶ Несмотря на регуляризацию, коэффициенты не падают в 0.



Ридж регрессия и выбор переменных

- ▶ Оценки коэффициентов в ридж регрессии равны 0 **только** в случае $\lambda = \infty$.
- ▶ Нельзя точно сказать, какие из регрессоров являются плохими.
- ▶ При этом, ридж регрессия для фиксированного параметра λ оптимизируется очень быстро.



Гребневая регрессия и друзья

- ▶ Гребневая регрессия, с регуляризацией

$$\lambda ||\beta||_2^2$$

- ▶ Является поднабором регуляризаций Тихонова

$$||\Gamma x||.$$

- ▶ При этом, как мы видели на предыдущей лекции, она же сводит частотные решения к байесовской оценке с гауссовскими априорными распределениями.

Выводы

- ▶ Регуляризация по типу ридж регрессии позволяет улучшить разнообразие прогноза.
- ▶ Лучшие улучшения достигаются при большом разнообразии настоящих значений коэффициентов.

Регрессия лассо



Least Absolute Selection and Shrinkage Operator


- ▶ Добавляем дополнительное слагаемое в оценку параметров для $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$:

$$\begin{aligned}\hat{\beta}^{lasso} &= \operatorname{argmin}_{\beta \in \mathbb{R}^p} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{i=1}^n |y_i - x_i^T \beta| = \\ &= \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1.\end{aligned}$$

- ▶ $\lambda \geq 0$ – свободный параметр (с такими же краевыми условиями).

Поведение коэффициентов регрессии


- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ Две группы коэффициентов β : 20 маленьких и 10 больших.
- ▶ $\lambda = 25$
- ▶ Оценки для «больших» снижаются. «маленькие» перемешиваются.



MSE


- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ Две группы коэффициентов β : 20 маленьких и 10 больших.
- ▶ $\lambda \in [0; 10]$.

Явный оптимум при
небольших λ .




MSE для случайных коэффициентов

- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ 30 коэффициентов β примерно одинакового масштаба.
- ▶ Лассо не даёт выигрыша, так как дисперсия падает слишком медленно.



Лассо регрессия для плохих регрессоров


- ▶ $n = 50, p = 30, \sigma^2 = 1$.
- ▶ 30 коэффициентов β : 10 значимых и 20 равных нулю.
- ▶ Лассо позволяет получить более глубокий минимум MSE.



Лассо как MAP оценка

- ▶ Как и ридж, лассо можно представить как результат байесовской регрессии с конкретным априорным распределением на коэффициенты:

$$\beta \sim \text{Laplace}(\lambda).$$




Промежуточные Выводы

- ▶ Регрессия лассо строится похожим образом с гребневой регрессией.
- ▶ Аналогично имеется байесовская интерпретация.
- ▶ Хуже работает при близких значениях коэффициентов.

Лассо, Ридж и выбор модели




Лассо и Ridge



Лассо обеспечивает равенство коэффициентов нулю.

Оператор сжатия

Estimator	Formula
Best subset (size M)	$\hat{\beta}_j \cdot I(\hat{\beta}_j \geq \hat{\beta}_{(M)})$
Ridge	$\hat{\beta}_j / (1 + \lambda)$
Lasso	$\text{sign}(\hat{\beta}_j)(\hat{\beta}_j - \lambda)_+$





Лассо мягко отрезает маленькие коэффициенты

Оптимизация

Интерпретация:


- $\hat{\beta}^{lasso} = \arg \min_{\beta} ||y - X\beta||^2, ||\beta||_1 \leq t$
- $\hat{\beta}^{ridge} = \arg \min_{\beta} ||y - X\beta||^2, ||\beta||_2 \leq t$



В случае лассо, решение приходит в угол, что обнуляет один из коэффициентов.

Интерпретация

- ▶ В отличие от ридж регрессии, регрессия лассо обнуляет незначащие коэффициенты.
- ▶ Это позволяет использовать L1 регуляризацию для выбора параметров.
- ▶ Другие виды ограничений возможны:



Обобщение регуляризаций

- ▶ В общем виде, можем выбрать регуляризацию:


$$\lambda ||\beta||_q.$$

- ▶ Это позволяет достигнуть необходимых свойств регуляризации.
- ▶ Каждая регуляризация имеет байесовскую интерпретацию.
- ▶ Только $q = 1$ даёт выпуклый функционал и возможность выбора переменных.



Эластичная сеть

- ▶ Иногда бывает необходимо объединить две регуляризации:
 - Много коррелированных переменных.
 - Необходимо выбрать часть из них, а с часть оставить с общими весами.
- ▶ Решение – сумма двух регуляризаций, эластичная сеть:

$$\lambda(\gamma \|\beta\|_1 + (1 - \gamma) \|\beta\|_2)$$



Эластичная сеть



Выбирается большее количество переменных, с меньшим конкретным весом

Применения лассо



non-zeros = 33.51%



13.58%



1.21%


- ▶ На практике спарсификация используется, например, при сжатии изображений.
- ▶ При преобразовании Фурье/Вейвлет, можно выбросить часть «ненужных» переменных.
- ▶ Такой подход использовался в сжатии jpeg.

Степени свободы

- ▶ Можно подсчитать количество степеней свободы для моделей регрессий с p коэффициентами:
 - Без регуляризации: $df = p$
 - Регуляризация ридж: $df = \text{Tr}(X(X^T X + \lambda I)^{-1} X^T)$
 - Регуляризация лассо: $df = \mathbb{E}(\text{ненулевых значений } \hat{\beta})$

Используется для примерного понимания декомпозиции ошибки и сравнения регуляризаций.

Степени свободы



Можно видеть разные поведения ridge и лассо

Общие выводы

- ▶ Регуляризации позволяют бороться с большим количеством специфических проблем линейной регрессии.
- ▶ Самые интересные типы регуляризации: ридж и лассо.
- ▶ Лассо можно использовать для выбора нужных регрессоров.