

Прикладная статистика

Регрессия гауссовскими процессами

Денис Деркач

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2026

В этой лекции

- ▶ Построение регрессии на основе гауссовских процессов.
- ▶ Интерпретация алгоритма с точки зрения байесовской регрессии.

Напоминание



Линейная регрессия

- ▶ Для набора данных: $\{(x^{(i)}; y^{(i)})\}_{i=1}^N$.
- ▶ Линейная модель:

$$\hat{y} = w^T \phi(x).$$

- ▶ Функция потерь:

$$\mathcal{L}(y, t) = \frac{1}{2} (\hat{y} - y)^2.$$

Решение:

$$w = (\phi^T \phi)^{-1} \phi^T y$$

Байесовская линейная регрессия

$$y_n = \mathbf{w}^T \mathbf{x}_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \sigma^2), \quad n = 1, \dots, N$$

$$\mathbf{w} \sim p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; \mathbf{m}_0, \Sigma_0)$$

- ▶ y_n – наблюдаемая **случайная** переменная
- ▶ w – неизвестный **случайная** переменная
- ▶ x_n – известная **фиксированная** переменная
- ▶ ε_n – неизвестная **случайная** переменная
- ▶ σ – известная **фиксированная** переменная

Все априорные распределения – нормальные.

Предсказание распределения

- ▶ Для новой точки (y_*, x_*) :

$$p(y_* | \mathbf{w}) = \mathcal{N}(y_*; x_*^T \mathbf{w}, \beta^{-1}), \text{ правдоподобие}$$

$$p(w | y) = N(w; m_N, S_N) \text{ апостериорное распределение}$$

- ▶ Используя $p(x_b) = \mathcal{N}(x_b; \mu_b, \Sigma_b)$, $x_a = w$, $x_b = y_*$. Получаем:

$$p(y_* | y) = N(y_*; m_*, s_*)$$

$$m_* = x_*^T m_N$$



$$s_* = \beta^{-1} + x_*^T S_N x_*$$

NB: для случая неизвестного β вместо нормального у нас появляется распределение t-распределение.

Мотивация



Регрессия




From A. Lindholm et al.

- ▶ **Дано:** набор точек $\{x_i; y_i\}_{i=1}^N$.
- ▶ **Предполагаем:** существует некоторая функция $y_i = f(x_i) + \varepsilon$.

Случай двух точек

- ▶ Для $N=2$: $x \in \{1; 2\}$.
- ▶ Хотим получить f_1 и f_2 .
- ▶ Предположим, что они распределены по гауссу.


$$\begin{bmatrix} f_1 \\ f_2 \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix} \right)$$



From A. Lindholm et al.





Случай двух точек

- ▶ В тренировочном наборе пришло измерение f_2 .
- ▶ Теперь мы знаем что-то про f_1 .




$$f_1 | f_2 \sim \mathcal{N} \left(\mu_1 + \frac{\sigma_{12}}{\sigma_2^2} (f_2 - \mu_2), \sigma_1^2 - \frac{\sigma_{12}^2}{\sigma_2^2} \right)$$

Случай двух точек




Больше точек

- ▶ Для $N=6$: $x \in \{1; 2; 3; 4; 5; 6\}$.
- ▶ Хотим получить:
$$f = [f_1; f_2; f_3; f_4; f_5; f_6]^T$$
- ▶ Предположим, что они
распределены по гауссу.



Больше точек

- ▶ Для $N=6$: $x \in \{1; 2; 3; 4; 5; 6\}$.
- ▶ Хотим получить:
$$f = [f_1; f_2; f_3; f_4; f_5; f_6]^T$$
- ▶ Предположим, что они
распределены по гауссу.
- ▶ Знаем f_4 .



Больше точек: расчёт

- ▶ Разделим f по блокам: $f = \begin{bmatrix} f_a \\ f_b \end{bmatrix}$:


$$\begin{bmatrix} f_a \\ f_b \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix}; \begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix} \right).$$

- ▶ Таким образом:

$$f_a | f_b \sim \mathcal{N}(\mu_a + \Sigma_{ab} \Sigma_{bb}^{-1} (f_b - \mu_b), \Sigma_{aa} - \Sigma_{ab} \Sigma_{bb}^{-1} \Sigma_{ba}).$$

- ▶ В нашем примере:

$$f_a | f_4$$



Дискретный набор

- ▶ Для любого n , $x \in \{1; \dots; n\}$, можем выписать

$$\begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_n^2 \end{bmatrix} \right)$$

- ▶ Где средние взяты 0 для упрощения.


Дискретный набор: обобщение

- ▶ Для любого n , $x \in \{1; \dots; n\}$, можем выписать


$$\begin{bmatrix} f(x_1) \\ f(x_2) \\ \vdots \\ f(x_n) \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \begin{bmatrix} \kappa(x_1, x_1) & \kappa(x_1, x_2) & \dots & \kappa(x_1, x_n) \\ \kappa(x_2, x_1) & \kappa(x_2, x_2) & \dots & \kappa(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ \kappa(x_n, x_1) & \kappa(x_n, x_2) & \dots & \kappa(x_n, x_n) \end{bmatrix} \right)$$

- ▶ Где средние взяты 0 для упрощения.
- ▶ $\kappa(x_i, x_j)$ – **функция ковариации** для **любого** набора наблюдений.


- ▶ Например:
$$\kappa(x, x') = \left(1 + \frac{|x - x'|^2}{2\alpha\ell} \right)^{-\alpha}$$



Регрессия как ГП



Ничего не знаем про данные



Получили первое измерение x_1^d

Вывод

- ▶ С помощью условных распределений мы можем уточнять распределения случайных величин из этого набора.
- ▶ Можно перейти от матрицы ковариаций к функции ковариаций. Она будет характеризовать ковариации для любого набора наблюдений.

Гауссовский процесс



Определение

Стохастический процесс $\{X_t: t \in T\}$ называется **Гауссовским процессом**, если для любого конечного набора индексов $\{t_i\}$:

$$X_{t_1, t_2, t_3, \dots, t_n} = (X_{t_1}, \dots, X_{t_n})$$

имеет гауссово распределение вероятностей.

Применение

- ▶ Для какого-то дизайна $\mathbf{X}$, полагая $f(\mathbf{X})$ многомерным гауссом

$$\mathbf{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}, f(\mathbf{X}) = \begin{bmatrix} f(x_1) \\ f(x_2) \\ \vdots \\ f(x_n) \end{bmatrix}, K(x_*, x_*) = \kappa(x_*, x_*).$$

- ▶ $\kappa(x, x)$ -- функция ковариации.

Для задания ГП достаточно функции ковариации.

Прогноз

- ▶ Хотим сделать прогноз для какой-то точки x_*




$$K(\mathbf{X}, x_*) = \begin{bmatrix} \kappa(x_1, x_*) \\ \vdots \\ \kappa(x_N, x_*) \end{bmatrix} = K(x_*, \mathbf{X})^\top \text{ and } K(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} \kappa(x_1, x_1) & \dots & \kappa(x_1, x_N) \\ \vdots & & \vdots \\ \kappa(x_N, x_1) & \dots & \kappa(x_N, x_N) \end{bmatrix}$$

- ▶ Получаем:

$$\begin{bmatrix} f(\mathbf{X}) \\ f(x_*) \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{0} \\ 0 \end{bmatrix}, \begin{bmatrix} K(\mathbf{X}, \mathbf{X}) & K(x_*, \mathbf{X}) \\ K(\mathbf{X}, x_*) & K(x_*, x_*) \end{bmatrix} \right)$$

Прогноз: финальное распределение




$$f(x_*) | f(\mathbf{X}) \sim \mathcal{N}(\mathbf{K}(x_*, \mathbf{X})\mathbf{K}(\mathbf{X}, \mathbf{X})^{-1}f(\mathbf{X}), K(x_*, x_*) - \mathbf{K}(\mathbf{X}, x_*)\mathbf{K}(\mathbf{X}, \mathbf{X})^{-1}\mathbf{K}(\mathbf{X}, x_*))$$



Распределение с шумом

- Обычно точки зашумлены $\varepsilon \sim N(0, \sigma_n^2)$


$$f(x_*) | \mathbf{y} \sim \mathcal{N}(\mathbf{K}(x_*, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, K(x_*, x_*) - K(x_*, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} K(\mathbf{X}, x_*))$$



Вероятности функций

- Обычно точки зашумлены $\varepsilon \sim N(0, \sigma_n^2)$

$$f(x_*) | \mathbf{y} \sim \mathcal{N}(\mathbf{K}(x_*, \mathbf{X})(K(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, K(x_*, x_*) - K(x_*, \mathbf{X})(K(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} K(\mathbf{X}, x_*))$$



- Можем построить последовательные точки, которые покажут нам какие функции могут описывать процесс, то есть мы построили вероятности над функциями.

http://mlss.tuebingen.mpg.de/2013/Hennig_2013_Animating_Samples_from_Gaussian_Distributions.pdf

Вывод

- ▶ С помощью гауссовских процессов можно построить регрессию, основанную на корреляционной функции.
- ▶ Апостериорная вероятность показывает распределение в пространстве функций.
- ▶ Первоначально предложена в геофизике Д. Криге, метод называется **кригинг**.

ГП и байесовская регрессия



Вернёмся к байесовской регрессии

- ▶ Для модели:

$$y = \mathbf{x}^T \mathbf{w} + \varepsilon, \varepsilon \sim N(0, \sigma_n^2)$$

- ▶ Модель будет выглядеть нормально:

$$p(\mathbf{y} | \mathbf{w}) = N(\mathbf{y}; \mathbf{X}\mathbf{w}, \sigma_n^2 \mathbf{I}_N).$$

- ▶ В случае нормального априорного распределения:

$$p(\mathbf{w}) = N(\mathbf{w}; \mathbf{0}, \mathbf{I})$$




- ▶ Получим

$$p(\mathbf{w} | \mathbf{y}) = \mathcal{N} \left(\mathbf{w}; \left(\mathbf{I} + \frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \left(\frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{y} \right), \left(\mathbf{I} + \frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \right)$$

Прогноз в байесовской регрессии

- Для некоторой точки x_*

$$p(f(\mathbf{x}_*) | \mathbf{y}) = \mathcal{N} \left(f(\mathbf{x}_*); \underbrace{\mathbf{x}_*^T \left(\mathbf{I} + \frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \left(\frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{y} \right)}_{\text{Апостериорное среднее}}, \underbrace{\mathbf{x}_*^T \left(\mathbf{I} + \frac{1}{\sigma_n^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \mathbf{x}_*}_{\text{Апостериорная дисперсия}} \right)$$



Преобразования переменных

- ▶ Предположим нелинейное преобразование:

$$\Phi(x) = [1, x, x^2]^T$$

- ▶ В этом случае, решение будет выглядеть:




$$p(f(x_\star) | \mathbf{y}) = \mathcal{N} \left(f(x_\star); \phi(x_\star)^\top \left(\mathbf{I} + \frac{1}{\sigma_n^2} \Phi^\top \Phi \right)^{-1} \left(\frac{1}{\sigma_n^2} \Phi^\top \mathbf{y} \right), \phi(x_\star)^\top \left(\mathbf{I} + \frac{1}{\sigma_n^2} \Phi^\top \Phi \right)^{-1} \phi(x_\star) \right)$$

- ▶ где

$$\Phi = \begin{bmatrix} \phi(x_1)^\top \\ \phi(x_2)^\top \\ \vdots \\ \phi(x_N)^\top \end{bmatrix}$$

Прогноз после преобразования

$$\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix}$$



Преобразование

$$p(f(x_*) | \mathbf{y}) = \mathcal{N} \left(f(x_*); \phi(x_*)^\top \left(\sigma_n^2 \mathbf{I} + \Phi^\top \Phi \right)^{-1} \left(\Phi^\top \mathbf{y} \right), \phi(x_*)^\top \left(\mathbf{I} + \frac{1}{\sigma_n^2} \Phi^\top \Phi \right)^{-1} \phi(x_*) \right)$$

Из линейной алгебры: $(I + A^T A)^{-1} A = A(I + A A^T)^{-1}$

$$\phi(x_*)^T (\sigma_n^2 I + \Phi^T \Phi)^{-1} \Phi^T y = \phi(x_*)^T \Phi^T (\sigma^2 I + \Phi \Phi^T)^{-1} y.$$

Инвертирование $(I + UV)^{-1} = I - U(I + VU)^{-1}V$

$$\phi(x_*)^T \left(I + \frac{1}{\sigma_n^2} \Phi^T \Phi \right)^{-1} \phi(x_*) = \phi(x_*)^T \phi(x_*) - \phi(x_*)^T \Phi^T (\sigma_n^2 I + \Phi \Phi^T)^{-1} \Phi \phi(x_*).$$

Ядерный трюк

$$\Phi = \begin{bmatrix} \phi(x_1)^\top \\ \phi(x_2)^\top \\ \vdots \\ \phi(x_N)^\top \end{bmatrix}$$

- Положим $\kappa(x, x') = \phi(x)^\top \phi(x')$, ядро

$$K(x_\star, x_\star) = \kappa(x_\star, x_\star) = \phi(x_\star)^\top \phi(x_\star)$$

$$K(\mathbf{X}, x_\star) = \begin{bmatrix} \kappa(x_1, x_\star) \\ \vdots \\ \kappa(x_N, x_\star) \end{bmatrix} = \begin{bmatrix} \phi(x_1)^\top \phi(x_\star) \\ \vdots \\ \phi(x_N)^\top \phi(x_\star) \end{bmatrix} = \Phi \phi(x_\star) = K(x_\star, \mathbf{X})^\top$$

$$K(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} \kappa(x_1, x_1) & \dots & \kappa(x_1, x_N) \\ \vdots & & \vdots \\ \kappa(x_N, x_1) & \dots & \kappa(x_N, x_N) \end{bmatrix} = \begin{bmatrix} \phi(x_1)^\top \phi(x_1) & \dots & \phi(x_1)^\top \phi(x_N) \\ \vdots & & \vdots \\ \phi(x_N)^\top \phi(x_1) & \dots & \phi(x_N)^\top \phi(x_N) \end{bmatrix} = \Phi \Phi^\top$$

Финальная форма


$$p(f(x_\star) | \mathbf{y}) = \mathcal{N}\left(f(x_\star); K(x_\star, \mathbf{X}) (\sigma_n^2 \mathbf{I} + K(X, X))^{-1} \mathbf{y}, \right. \\ \left. K(x_\star, x_\star) - K(x_\star, \mathbf{X}) (\sigma_n^2 \mathbf{I} + K(X, X))^{-1} K(\mathbf{X}, x_\star) \right)$$

- ▶ Имеет ту же форму, что и регрессия из гауссовского процесса.
- ▶ Дизайн появляется только в ядре $\kappa(x, x') = \phi(x)^T \phi(x')$.
- ▶ Выбирая ядро, мы фиксируем нелинейное преобразование входных переменных.

Ядро = функция ковариации


Squared exponential/RBF

$$\kappa(x, x') = \sigma^2 \exp\left(-\frac{1}{2\ell^2} (x - x')^2\right)$$




Rational quadratic

$$\kappa(x, x') = \sigma^2 \left(1 + \frac{|x - x'|^2}{2\alpha\ell}\right)^{-\alpha}$$




Matérn 1

$$\kappa(x, x') = \sigma^2 \exp\left(-\frac{1}{\ell^2} |x - x'|\right)$$



Periodic kernel

$$\kappa(x, x') = \sigma^2 \exp\left(-\frac{2}{\ell^2} \sin^2\left(\pi \frac{|x - x'|}{p}\right)\right)$$




Вывод

- ▶ Байесовская интерпретация регрессии на гауссовских процессах показывает, что выбор функции ковариации связан с выбором преобразований входных переменных.
- ▶ Таким образом, фактически выбором функции ковариации фиксируется набор функций, которым мы приближаем поведение системы.
- ▶ Полезно для решения обратной задачи.

Построение карты магнитного поля

Цвет = апостериорное среднее (сила магнитного поля; величина, представляющая интерес).

Прозрачность = апостериорное отклонение (более прозрачный означает большее отклонение). .



<https://www.youtube.com/watch?v=enlMiUqPVJo>

N. Wahlström et al, **Modeling magnetic fields using Gaussian processes** *The 38th International Conference on Acoustics, Speech, and Signal Processing*

Вывод

- ▶ Гауссовские процессы позволяют построить широкий класс регрессий.
- ▶ Подбор гиперпараметров и ядер – отдельная проблема.