

Прикладная статистика

Настройка регрессий гауссовскими процессами

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Настройка регрессии гауссовскими процессами:
 - выбор и конструирование ковариационной функции;
 - подбор гиперпараметров.

Напоминание



Определение

Стохастический процесс $\{X_t: t \in T\}$ называется **Гауссовским процессом**, если для любого конечного набора индексов $\{t_i\}$:

$$X_{t_1, t_2, t_3, \dots, t_n} = (X_{t_1}, \dots, X_{t_n})$$

имеет гауссово распределение вероятностей.

Применение

- ▶ Для какого-то дизайна X , полагая $f(X)$ многомерным гауссом

$$\mathbf{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}, f(\mathbf{X}) = \begin{bmatrix} f(x_1) \\ f(x_2) \\ \vdots \\ f(x_n) \end{bmatrix}, K(x_*, x_*) = \kappa(x_*, x_*).$$

- ▶ $\kappa(x, x)$ -- функция ковариации.

Для задания ГП достаточно функции ковариации.

Прогноз

- ▶ Хотим сделать прогноз для какой-то точки x_*




$$K(\mathbf{X}, x_*) = \begin{bmatrix} \kappa(x_1, x_*) \\ \vdots \\ \kappa(x_N, x_*) \end{bmatrix} = K(x_*, \mathbf{X})^\top \text{ and } K(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} \kappa(x_1, x_1) & \dots & \kappa(x_1, x_N) \\ \vdots & & \vdots \\ \kappa(x_N, x_1) & \dots & \kappa(x_N, x_N) \end{bmatrix}$$

- ▶ Получаем:

$$\begin{bmatrix} f(\mathbf{X}) \\ f(x_*) \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{0} \\ 0 \end{bmatrix}, \begin{bmatrix} K(\mathbf{X}, \mathbf{X}) & K(x_*, \mathbf{X}) \\ K(\mathbf{X}, x_*) & K(x_*, x_*) \end{bmatrix} \right)$$

Прогноз: финальное распределение




$$f(x_*) | f(\mathbf{X}) \sim \mathcal{N}(\mathbf{K}(x_*, \mathbf{X})\mathbf{K}(\mathbf{X}, \mathbf{X})^{-1}f(\mathbf{X}), K(x_*, x_*) - \mathbf{K}(\mathbf{X}, x_*)\mathbf{K}(\mathbf{X}, \mathbf{X})^{-1}\mathbf{K}(\mathbf{X}, x_*))$$



Распределение с шумом

- Обычно точки зашумлены $\varepsilon \sim N(0, \sigma_n^2)$


$$f(x_\star) | \mathbf{y} \sim \mathcal{N}(\mathbf{K}(x_\star, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, K(x_\star, x_\star) - K(x_\star, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} K(\mathbf{X}, x_\star))$$



Вероятности функций

- Обычно точки зашумлены $\varepsilon \sim N(0, \sigma_n^2)$

$$f(x_*) | \mathbf{y} \sim \mathcal{N}(\mathbf{K}(x_*, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, K(x_*, x_*) - K(x_*, \mathbf{X})(\mathbf{K}(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} K(\mathbf{X}, x_*))$$





- Можем построить последовательные точки, которые покажут нам какие функции могут описывать процесс, то есть мы построили вероятности над функциями.

http://mlss.tuebingen.mpg.de/2013/Hennig_2013_Animating_Samples_from_Gaussian_Distributions.pdf

Выбор ковариационных функций



Мотивация: выбор ковариационных функций





- ▶ Выбор ковариационной функции эквивалентен выбору класса приближающих функций.
- ▶ Ковариационная функция полностью определяет ГП.

<http://www.it.uu.se/edu/course/homepage/apml/GP/>

Квадратичная экспоненциальная функция

$$k(x, x') = \sigma_f^2 \exp\left(-\frac{(x-x')^2}{2\ell^2}\right)$$

- ▶ Radial-Basis Function (RBF) или Squared Exponential (SE)
- ▶ Гиперпараметры:
 - ℓ отвечает за ширину гаусса, то есть структур функции, то есть за возможность экстраполяции;
 - σ_f^2 за размах флуктуаций функций.





<http://www.gaussianprocess.org/gpml/chapters/RW4.pdf>

<https://www.cs.toronto.edu/~duvenaud/cookbook/>

Квадратичная экспоненциальная функция

$$k(x, x') = \sigma_f^2 \exp\left(-\frac{(x-x')^2}{2\ell^2}\right)$$



- ▶ Ковариационная функция определяет из каких функций строится приближение.
- ▶ Для RBF мы предполагаем гладкость. Для прыжков:
 - $\ell \rightarrow 0$
 - зашумлённые средние.



Периодическая ковариационная функция

$$k(x, x') = \sigma_f^2 \exp \left(-\frac{2}{\ell^2} \sin^2 \left(\pi \frac{x-x'}{p} \right) \right)$$

- ▶ Periodic (Per)
- ▶ Гиперпараметры:
 - ℓ отвечает за ширину гаусса, то есть за структуру функции, то есть за возможность экстраполяции;
 - p за величину периода;
 - σ_f^2 за размах флуктуаций функций.





Линейная ковариационная функция

$$k(x, x') = \sigma_f^2(x - c)(x' - c)$$

- ▶ Linear (Lin)
- ▶ Гиперпараметры:
 - c координата апостериорного пересечения всех функций;
 - σ_f^2 за размах флуктуаций функций.

Зависит от абсолютных значений.



Стационарные и нестационарные кф

- ▶ Стационарные:
 - зависят от запаздывания $|x - x'|$;
 - RBF, Per.
- ▶ Нестационарные:
 - зависят от значения точки;
 - Lin;
 - предсказание может меняться при смещении данных.

Вывод

- ▶ Выбор ковариационных функций определяет:
 - класс функций, откуда будут выбираться последовательности;
 - это может влиять на качество экстраполяции и интерполяции (функции могут оказаться дифференцируемы).
- ▶ Знание структуры задачи позволяет сократить требования к данным.
- ▶ Даже для нулевого среднего предсказание может быть не ноль.

Новые ковариационные функции



Матрица Грама для КФ

- ▶ Матрица Грама:

$$K(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} \kappa(x_1, x_1) & \dots & \kappa(x_1, x_N) \\ \vdots & & \vdots \\ \kappa(x_N, x_1) & \dots & \kappa(x_N, x_N) \end{bmatrix}$$

должна быть неотрицательно неопределённой.

Требование к КФ.

Использование существующих КФ


- ▶ Можем использовать простые функции от ядер

$$\kappa_{\times}(x, x') = \kappa_1(x, x')\kappa_2(x, x')$$

$$\kappa_{+}(x, x') = \kappa_1(x, x') + \kappa_2(x, x')$$

Не выводят за пределы требований КФ.


Перемножение КФ



Усиливает модель, дополняя её новыми функциями

Automatic Relevance Determination (ARD)

$$\text{SE-ARD}(\mathbf{x}, \mathbf{x}') = \prod_{d=1}^D \sigma_d^2 \exp \left(-\frac{1}{2} \frac{(x_d - x'_d)^2}{\ell_d^2} \right) = \sigma_f^2 \exp \left(-\frac{1}{2} \sum_{d=1}^D \frac{(x_d - x'_d)^2}{\ell_d^2} \right)$$



Автоматически устанавливает «релевантность» в зависимости от масштаба ℓ_D .

Универсальное ядро (может приблизить любую функцию, при достаточном количестве данных).

Связь с регрессией

- ▶ Для комбинации двух ядер:


$$k_a(\mathbf{x}, \mathbf{x}') = \mathbf{a}(\mathbf{x})^\top \mathbf{a}(\mathbf{x}')$$

$$k_b(\mathbf{x}, \mathbf{x}') = \mathbf{b}(\mathbf{x})^\top \mathbf{b}(\mathbf{x}')$$

- ▶ произведение


$$\begin{aligned} k_a(\mathbf{x}, \mathbf{x}') \times k_b(\mathbf{x}, \mathbf{x}') &= \left[\mathbf{a}(\mathbf{x})^\top \mathbf{a}(\mathbf{x}') \right] \times \left[\mathbf{b}(\mathbf{x})^\top \mathbf{b}(\mathbf{x}') \right] \\ &= \sum_i a_i(\mathbf{x}) a_i(\mathbf{x}') \times \sum_j b_j(\mathbf{x}) b_j(\mathbf{x}') \\ &= \sum_{i,j} \left[a_i(\mathbf{x}) b_j(\mathbf{x}) \right] \left[a_i(\mathbf{x}') b_j(\mathbf{x}') \right] \end{aligned}$$

Сумма ядер



Задаёт структуру модели

Многомерный случай



$$f_1(x_1) \sim \mathcal{GP}(0, k_1(x_1, x'_1))$$

$$f_2(x_2) \sim \mathcal{GP}(0, k_2(x_2, x'_2))$$

$$f(x_1, x_2) = f_1(x_1) + f_2(x_2).$$

Связь с регрессией

- ▶ Для комбинации двух ядер:

$$k_a(\mathbf{x}, \mathbf{x}') = \mathbf{a}(\mathbf{x})^\top \mathbf{a}(\mathbf{x}')$$

$$k_b(\mathbf{x}, \mathbf{x}') = \mathbf{b}(\mathbf{x})^\top \mathbf{b}(\mathbf{x}')$$

- ▶ Сумма

$$k_a(\mathbf{x}, \mathbf{x}') + k_b(\mathbf{x}, \mathbf{x}') = \mathbf{a}(\mathbf{x})^\top \mathbf{a}(\mathbf{x}') + \mathbf{b}(\mathbf{x})^\top \mathbf{b}(\mathbf{x}') = \begin{bmatrix} \mathbf{a}(\mathbf{x}) \\ \mathbf{b}(\mathbf{x}) \end{bmatrix}^\top \begin{bmatrix} \mathbf{a}(\mathbf{x}') \\ \mathbf{b}(\mathbf{x}') \end{bmatrix}$$

Конкатинация преобразований

Апостериорная ковариация для сложения

- ▶ Матрица Грама для дизайна X и предсказаний X^* :

$$\mathbf{K}_i = k_i(\mathbf{X}, \mathbf{X})$$

$$\mathbf{K}_i^* = k_i(\mathbf{X}, \mathbf{X}^*)$$

$$\mathbf{K}_i^{**} = k_i(\mathbf{X}^*, \mathbf{X}^*)$$

$$\begin{bmatrix} f_1(\mathbf{X}) \\ f_1(\mathbf{X}^*) \\ f_2(\mathbf{X}) \\ f_2(\mathbf{X}^*) \\ f_1(\mathbf{X}) + f_2(\mathbf{X}) \\ f_1(\mathbf{X}^*) + f_2(\mathbf{X}^*) \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_1 \\ \mu_1^* \\ \mu_2 \\ \mu_2^* \\ \mu_1 + \mu_2 \\ \mu_1^* + \mu_2^* \end{bmatrix}, \begin{bmatrix} \mathbf{K}_1 & \mathbf{K}_1^* & 0 & 0 & \mathbf{K}_1 & \mathbf{K}_1^* \\ \mathbf{K}_1^{*\top} & \mathbf{K}_1^{**} & 0 & 0 & \mathbf{K}_1^* & \mathbf{K}_1^{**} \\ 0 & 0 & \mathbf{K}_2 & \mathbf{K}_2^* & \mathbf{K}_2 & \mathbf{K}_2^* \\ 0 & 0 & \mathbf{K}_2^{*\top} & \mathbf{K}_2^{**} & \mathbf{K}_2^* & \mathbf{K}_2^{**} \\ \mathbf{K}_1 & \mathbf{K}_1^{*\top} & \mathbf{K}_2 & \mathbf{K}_2^{*\top} & \mathbf{K}_1 + \mathbf{K}_2 & \mathbf{K}_1^* + \mathbf{K}_2^* \\ \mathbf{K}_1^{*\top} & \mathbf{K}_1^{**} & \mathbf{K}_2^{*\top} & \mathbf{K}_2^{**} & \mathbf{K}_1^{*\top} + \mathbf{K}_2^{*\top} & \mathbf{K}_1^{**} + \mathbf{K}_2^{**} \end{bmatrix} \right)$$


Тогда

$$f_1(\mathbf{X}^*) | f_1(\mathbf{X}) + f_2(\mathbf{X}) \sim \mathcal{N} \left(\mu_1^* + \mathbf{K}_1^{*\top} (\mathbf{K}_1 + \mathbf{K}_2)^{-1} [f_1(\mathbf{X}) + f_2(\mathbf{X}) - \mu_1 - \mu_2], \right. \\ \left. \mathbf{K}_1^{**} - \mathbf{K}_1^{*\top} (\mathbf{K}_1 + \mathbf{K}_2)^{-1} \mathbf{K}_1^* \right)$$


Экстраполяции

True function:


$$f(x_1, x_2) = \sin(x_1) + \sin(x_2)$$



GP mean using
sum of SE kernels:
 $k_1(x_1, x'_1) + k_2(x_2, x'_2)$



GP mean using
product of SE kernels:
 $k_1(x_1, x'_1) \times k_2(x_2, x'_2)$



Из-за дополнительной структуры, модель с суммой ядер зачастую проще экстраполирует, чем модель с произведением.



Вывод

- ▶ Матрица Грама должна быть неотрицательно определена.
- ▶ Новые ковариационные функции можно получить из старых сложением и перемножением.
- ▶ Добавление структуры позволяет сэкономить на данных.

Настройка гиперпараметров



Мотивация: настройка гиперпараметров



- Выбор гиперпараметров:
 - кроссвалидация;
 - максимизация апостериорного распределения.

<http://www.it.uu.se/edu/course/homepage/apml/GP/>
<http://www.gaussianprocess.org/gpml/chapters/RW5.pdf>

Маргинальное правдоподобие

- ▶ Выпишем ГП:

$$p(f \mid \theta) = \mathcal{GP}(f; \mu(\mathbf{x}; \theta), K(\mathbf{x}, \mathbf{x}'; \theta))$$

- ▶ Будем измерять качество нашей модели по вероятности увидеть такие данные:

$$p(\mathbf{y} \mid \mathbf{X}, \theta) = \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}, \theta) d\mathbf{f},$$

θ – гиперпараметр, интеграл по всем возможным функциям.

Маргинальное правдоподобие

Этот интеграл можно взять аналитически, если все распределения гауссовы

$$\begin{aligned} p(\mathbf{y} \mid \mathbf{X}, \theta) &= \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}, \theta) d\mathbf{f}, \\ &= \int \mathcal{N}(\mathbf{y}; \mathbf{f}, \sigma^2 \mathbf{I}) \mathcal{N}(\mathbf{f}; \mu(\mathbf{X}; \theta), K(\mathbf{X}, \mathbf{X}; \theta)) d\mathbf{f} \\ &= \mathcal{N}(\mathbf{y}; \mu(\mathbf{X}; \theta), K(\mathbf{X}, \mathbf{X}; \theta) + \sigma^2 \mathbf{I}). \end{aligned}$$

Лог-правдоподобие





В этом случае, можем выписать лог-правдоподобие

(для $V = K(X, X; \theta) + \sigma^2 I$):

$$\log p(\mathbf{y} \mid \mathbf{X}, \theta) =$$
$$-\frac{\overset{\text{data fit}}{(\mathbf{y} - \boldsymbol{\mu})^\top \mathbf{V}^{-1} (\mathbf{y} - \boldsymbol{\mu})}}{2} - \overset{\text{Occam's razor}}{\frac{\log \det \mathbf{V}}{2}} - \frac{N \log 2\pi}{2}$$



Первое слагаемое отвечает за качество описание данных, второе за объём априорного распределения, то есть старается сделать модель проще.

Выбор модели: SE



Маргинализация: SE




$$p(\mathbf{y} \mid \mathbf{X}, \theta) = \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}, \theta) d\mathbf{f}$$



- ▶ Оптимизировать параметры пока апостериорная вероятность не максимизируется.

Маргинализация: SE

- ▶ Может быть несколько решений.



Вывод

- ▶ Маргинализированное правдоподобие можно использовать для подбора гиперпараметров.
- ▶ Также используют кросс-валидацию.

Выводы

- ▶ Варьирование и комбинирование ковариационных функций ведёт к улучшению качества регрессии.
- ▶ Существуют несколько способов оптимизации гиперпараметров.