

Прикладная статистика

Дизайн экспериментов

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2021

В этой лекции

- ▶ Что делать, если шансов получить данные мало?
- ▶ Как оптимально планировать эксперимент?
- ▶ Как оптимизировать функции, заданные неявно?

Мотивация



Мотивация

Задачи

- ▶ сравнительный эксперимент - сравнение двух разных моделей;
- ▶ наблюдательный эксперимент - упрощение модели;
- ▶ поиск оптимальной точки недоступной функции;
- ▶ регрессия.

Во всех случаях стоимость вычислений может быть достаточно высокой.


Суррогатное моделирование

$X = \{\mathbf{x}_i\}_{i=1}^N, \mathbf{x}_i \in X$ называется планом эксперимента.

$D = (X, Y = f(X)) = \{(\mathbf{x}_1, \mathbf{y}_1 = f(\mathbf{x}_1)), \dots, (\mathbf{x}_N, \mathbf{y}_N = f(\mathbf{x}_N))\}$ – обучающая выборка размера N .

► $\hat{f}(x) \approx f(x)$ **суррогатная** модель (функция), построенная по обучающей выборке $D = (X, Y = f(X))$.

- Требования к f :
- Легко и эффективно оценивается.
- “Близка” к f по значениям не только из D .



Вывод

- ▶ В случае трудоёмкости проведения эксперимента эффекты дизайна могут играть решающую роль при решении задачи.

Заполнение пространства



Равномерное заполнение пространства

- ▶ **Предположение:** мы ничего не знаем о суррогатной модели и указанных зависимостях.
- ▶ Будем заполнять пространство дизайна **равномерно**.


Плюсы

- ▶ Гибкость.
- ▶ Расширяемость.

Минусы

- ▶ Нет гарантий равномерности.

<https://www.itl.nist.gov/div898/handbook/pri/section3/pri3.htm>



Критерии равномерности

Пусть $\mathbb{X} = [0, 1]^d$.

› Discrepancy

$$d(X) = \sup_{0 \leq u_k < v_k < 1} \left| \frac{\#(X \cap P_{u,v})}{N} - |P_{u,v}| \right|, \quad P_{u,v} = \bigotimes_k [u_k, v_k),$$

› Минимаксное расстояние между точками

$$\rho(X) = \max_i \min_{j, j \neq i} \|\mathbf{x}_i - \mathbf{x}_j\|$$

› ϕ -метрика


$$\phi_p(X) = \left(\sum_{i < j} \|\mathbf{x}_i - \mathbf{x}_j\|^{-p} \right)^{1/p}$$

Чем равномернее, тем ниже значение метрики.

Латинские гиперкубы


Семплирование латинским гиперкубом:

- ▶ Разделения значений каждой компоненты дизайна на N равных интервалов.
- ▶ В каждый из которых семплируем ровно по одной точке.




Оптимизированные латинские гиперкубы

- ▶ LHS может иногда давать нежелательный результат.
- ▶ В OLHS генерируется множество LHS дизайнов
- ▶ Выбирается лучший LHS по равномерной метрике.



V




Оптимизированные латинские гиперкубы

Плюсы


- ▶ Проекции на оси достаточно равномерны.
- ▶ Простота.

Минусы

- ▶ Оптимизация очень медленная.
- ▶ Практически невозможно дополнить множество дизайна без нарушения свойств латинского гиперкуба.



Полный факторный план эксперимента



Равномерное разбиение пространства дизайна на узлы

Плюсы

- ▶ Хорошо заполняет пространство.
- ▶ Очень быстро генерируется.

Минусы

- ▶ Требуемое количество точек растёт слишком быстро.
- ▶ Невозможно дополнить.

Последовательность Холтона

- › Для заданной константы p определим ψ_p как

$$\psi_p(n) = \sum_{i=0}^{R(n)} \frac{a_i(n)}{p^{i+1}},$$


где a_i это числа из записи n в системе счисления с основанием p , а $R(n)$ обозначает максимальный индекс, для которого $a_i(n)$ не ноль.

- › n -й элемент последовательности Холтона это

$$\mathbf{x}_n = (\psi_{p_1}(n), \dots, \psi_{p_{d_{in}}}(n)),$$

где p_i это i -е простое число.

Последовательность Холтона





Плюсы

- ▶ Эффективность в малых размерностях.
- ▶ Всегда можно расширить добавлением новых точек.
 - › Быстрая генерация.

Минусы

- ▶ Проекции с высокой размерностью ($d > 6$) сильно коррелированы.

Другие последовательности



<https://habr.com/ru/post/440892/>

Вывод

- ▶ Равномерное заполнение используется для дизайна в отсутствии откликов.
- ▶ Дизайн может быть случайным (OLHS, Random) или детерминированным (Холтон, полный факторный).
- ▶ Оптимальные дизайны имеют способ добавления новых точек (Холтон и др).

Метод поверхности отклика




Суррогатное моделирование

$X = \{\mathbf{x}_i\}_{i=1}^N, \mathbf{x}_i \in X$ называется планом эксперимента.

$D = (X, Y = f(X)) = \{(\mathbf{x}_1, \mathbf{y}_1 = f(\mathbf{x}_1)), \dots, (\mathbf{x}_N, \mathbf{y}_N = f(\mathbf{x}_N))\}$ – обучающая выборка размера N .

► $\hat{f}(x) \approx f(x)$ **суррогатная** модель (функция), построенная по обучающей выборке $D = (X, Y = f(X))$.

- Требования к f :
- Легко и эффективно оценивается.
- “Близка” к f по значениям не только из D .



Поверхность отклика


Response Surface Model (RSM):

$$\hat{f}(\mathbf{x}) = \alpha_0 + \sum_{i=1}^{d_{in}} \alpha_i x_i + \sum_{i,j=1, i \leq j}^{d_{in}} \beta_{ij} x_i x_j \longleftrightarrow$$
$$\mathbf{x} = (x_1, \dots, x_{d_{in}}) \in \mathbb{X}.$$

Параметры RSM настраиваются по обучающей выборке $D = (X, Y = f(X))$ с заранее заданным $X = (\mathbf{x}_i)_{i=1}^N$.

Поверхность отклика

- ▶ Модели RSM:
 - линейная (все $\beta_{ij} = 0$);
 - RSM с перекрёстными членами ($\beta_{ii} = 0$ для всех i);
 - квадратичная
 - другие.



Оптимальные Дизайны для RSM

- ▶ Оптимальные дизайны минимизируют для RSM одну из величин:
 - дисперсию оценки параметров RSM (D-optimality);
 - дисперсию прогноза модели. (IV-optimality).
- ▶ Оптимальные дизайны уменьшают стоимость эксперимента посредством того, что статистическая модель может быть оценена через меньшее число запусков.

Построение поверхности отклика

- › RSM может быть записан в виде

$$\hat{f}(\mathbf{x}) = \psi(\mathbf{x})\mathbf{c},$$

где $\mathbf{c} = (\mathbf{a}, \mathbf{b})$ и ψ — соответствующее отображение.

Например

$\psi(\mathbf{x}) = (1, x_1, \dots, x_{d_{in}}, x_1x_2, x_1x_3, \dots, x_{d_{in}-1}x_{d_{in}})$ для RSM с перекрёстными членами.

- › $\psi(X)$ будет обозначать $(\psi(\mathbf{x}_1), \dots, \psi(\mathbf{x}_N))$.

Нахождение оптимальных параметров

- › Предположим, что шум нормальный: $\mathbf{c} \sim \mathcal{N}(\hat{\mathbf{c}}, \text{Cov}(\hat{\mathbf{c}}|X))$.
- › Метод наименьших квадратов даёт оценку ковариации $\hat{\mathbf{c}}$.

$$\text{Cov}(\hat{\mathbf{c}}|X) \sim (\psi(X)^T \psi(X))^{-1}.$$

- › Аналогично для прогноза ответа
 $f(\mathbf{x}_0) \sim \mathcal{N}(\hat{f}(\mathbf{x}_0), \text{Var}(\hat{f}|X))$.
- › Дисперсия прогноза $\hat{f}(\mathbf{x}_0) = \psi(\mathbf{x}_0)\hat{\mathbf{c}}$ в точке $\mathbf{x}_0 \in \mathbb{X}$.

$$\text{Var}(\hat{f}|X) \sim \psi(\mathbf{x}_0) (\psi(X)^T \psi(X))^{-1} \psi(\mathbf{x}_0)^T.$$

Критерий оптимальности: D-оптимальность

- › Критерий D-оптимальности даёт такой дизайн, что детерминант должен быть минимален:

$$\det \left[\left(\psi(X)^T \psi(X) \right)^{-1} \right] \rightarrow \min_X.$$


- › D-оптимальный дизайн минимизирует дисперсию оценки параметров.

Критерий оптимальности: IV-оптимальность


- › IV-оптимальный дизайн минимизирует дисперсия итогового прогноза модели:

$$\int_{\mathbb{X}} \psi(\mathbf{x}) \left(\psi(X)^T \psi(X) \right)^{-1} \psi(\mathbf{x})^T d\mathbf{x} \rightarrow \min_X .$$


D-оптимальность



True



Random



RSM

- ▶ Пример качества оценки с тем же количеством экспериментов для случайного и RSM D-оптимального дизайна.

Алгоритм Фёдорова

1. Установить число уровней для каждой переменной.
2. Сгенерировать полный факторный дизайн.
3. Взять необходимое число точек из множества кандидатов случайным образом и посчитать для них оптимальный критерий.
4. Продолжить оптимизацию добавлением и исключением точек из дизайна с целью минимизировать значение функционала.

DoE для RSM

Плюсы

- ▶ Даёт наилучшие возможные оценки для Response Surface Models.
- ▶ Требуется меньшее число запусков эксперимента, чем классические дизайны с той же точностью.
- ▶ Позволяет использовать категориальные переменные.

Минусы

- ▶ Эффективность доказана только для Response Surface Model с априори заданной структурой.

Вывод

- ▶ Метод поверхности отклика более эффективен в построении экспериментальных дизайнов, чем случайные дизайны.
- ▶ Дополнительно можно оптимизировать полный факторный план (Box-Benhken design).

Адаптивный дизайн



Адаптивный дизайн

Адаптивный DoE – это метод, который итеративно добавляет точки к обучающей выборке, минимизируя ошибку модели.




Рис.: Неизвестная функция




Рис.: Изначальные и добавленные точки




Рис.: Изначальная модель





Рис.: Конечная модель

Процесс адаптации

- ▶ Суррогатная модель содержит в себе информацию о поведении настоящей функции.
- ▶ Адаптивное обновление обучающей выборки даёт гибкие возможности для изменения числа точек.



Вывод

- ▶ Адаптивный дизайн позволяет строить более точную модель на основе всей доступной информации, поступающей последовательно.
- ▶ АД требует большего количества вычислений (надо пересчитывать каждый раз).

Регрессия ГП как сурогатная модель



Регрессия гауссовского процесса

$D = (X, \mathbf{y}) = \{(\mathbf{x}_i, y_i = f(\mathbf{x}_i) + \varepsilon(\mathbf{x}_i))\}_{i=1}^N$ — обучающее множество.

Здесь и далее для простоты возьмём $d_{out} = 1$, то есть $Y = \mathbf{y} \in \mathbb{R}^1$.
Апостериорное распределение $f(\mathbf{x})$:

$$\text{Law}(f(\mathbf{x})|D) = \mathcal{N}(\hat{f}(\mathbf{x}), \hat{\sigma}^2(\mathbf{x})).$$

Регрессия гауссовского процесса

- › Апостериорное среднее, используемое как выход суррогатной модели $\hat{f}(\mathbf{x})$, имеет вид:

$$\hat{f}(\mathbf{x}) = \mathbf{k}(\mathbf{x})^T (\mathbf{K} + \tilde{\sigma}^2 \mathbf{I})^{-1} \mathbf{y},$$

где $\mathbf{K} = \{k(\mathbf{x}_i, \mathbf{x}_j)\}_{i,j=1}^N$, $\mathbf{k}(\mathbf{x}) = \{k(\mathbf{x}, \mathbf{x}_i)\}_{i=1}^N$.

- › Апостериорная ковариация, используемая как оценка точности, имеет вид:

$$\hat{\sigma}^2(\mathbf{x}) = k(\mathbf{x}, \mathbf{x}) - \mathbf{k}(\mathbf{x})^T (\mathbf{K} + \tilde{\sigma}^2 \mathbf{I})^{-1} \mathbf{k}(\mathbf{x}).$$

Ковариационная функция

Если у нас нет информации о ковариационной функции используем:

› Взвешенное Евклидово расстояние:


$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp \left(- \sum_{i=1}^{d_{in}} \theta_i^2 (x_i - x'_i)^s \right), s \in [1, 2],$$

› Расстояние Махаланобиса:

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp \left(- (\mathbf{x} - \mathbf{x}')^T \Theta (\mathbf{x} - \mathbf{x}') \right),$$

где Θ это $d_{in} \times d_{in}$ матрица.

Регрессия гауссовского процесса



Выбор следующей точки

- ▶ Процедура выбора новой точки для дизайна может быть сформулирована как задача оптимизации некоторого критерия

$$\mathbf{x}_{new} = \arg \max_{\mathbf{x} \in \mathbb{X}} \mathcal{I}(\mathbf{x} | D, \hat{f}, \hat{\sigma}^2),$$

где $\mathcal{I}(\mathbf{x} | D, \hat{f}, \hat{\sigma}^2)$ - это критерий выбора точек, основанный на обучающем множестве D , текущей аппроксимации $\hat{f}$ и текущей ошибке $\hat{\sigma}^2$.

Критерий максимальной дисперсии

Критерий максимальной дисперсии это

$$\mathcal{I}_{MV}(\mathbf{x}) = \hat{\sigma}^2(\mathbf{x}|X),$$

где $\hat{\sigma}^2(\mathbf{x}|X)$ - ошибка обученной на $D = (X, \mathbf{y})$ аппроксимации в точке $\mathbf{x}$.

Плюсы


- ▶ Легко вычислим.
- ▶ Включает информацию о поведении функции.

Минусы

- ▶ Учитывается только локальное поведение.
- ▶ Склонна давать точки ближе к границе X .

Поверхность $\mathcal{J}_{MV}$

- ▶ Мультимодальность.
- ▶ Относительная регулярность.



Минимизация средней ошибки предсказания

Оптимальный критерий для минимизация ожидаемой среднего квадрата ошибки аппроксимации на следующей итерации:

$$\mathcal{I}_{\rho_2}(\mathbf{x}) = \frac{1}{|\mathbb{X}|} \int_{\mathbb{X}} (\hat{\sigma}^2(\mathbf{v}|X) - \hat{\sigma}^2(\mathbf{v}|X \cup \mathbf{x})) d\mathbf{v},$$

где

- › $\hat{\sigma}^2(\mathbf{v}|X)$ - ошибка предсказания аппроксимации построенной на множестве $D = (X, \mathbf{y})$.
- › $\hat{\sigma}^2(\mathbf{v}|X \cup \mathbf{x})$ - ошибка предсказания аппроксимации построенной на множестве $D^{ext} = D \cup (\mathbf{x}, y(\mathbf{x}))$.

Поверхность $\mathcal{I}_{\rho^2}$

Некоторые матричные вычисления позволяют выразить этот критерий следующим образом:


$$\mathcal{I}_{\rho^2}(\mathbf{x}) = \frac{1}{|\mathbb{X}|} \int_{\mathbb{X}} \frac{\hat{K}^2(\mathbf{x}, \mathbf{v})}{\hat{\sigma}^2(\mathbf{x} | X)} d\mathbf{v},$$

где $\hat{K}(\mathbf{x}, \mathbf{v}) = K(\mathbf{x}, \mathbf{v}) - \mathbf{k}(\mathbf{x})K^{-1}\mathbf{k}(\mathbf{v})^T$ — апостериорная ковариация между значениями гауссовского процесса в точках $\mathbf{x}$ и $\mathbf{v}$.

- Критерий может быть вычислительно нестабильным, если $\hat{\sigma}^2(\mathbf{x} | X)$ мало. Это ведёт к зашумленным значениям и к множественным неробастным минимумам.

Поверхность $\mathcal{J}_{\rho^2}$

- ▶ Мульти-modalность.
- ▶ Узкие и не робастные локальные минимумы. .



Integrated MSE Gain-Maximum Variance

Integrated MSE Gain-Maximum Variance критерий — это

$$\mathcal{I}_{IGMV}(\mathbf{x}) = \mathcal{I}_{\rho_2}(\mathbf{x}) * \mathcal{I}_{MV}(\mathbf{x}).$$

Плюсы

- ▶ Включает информацию о поведении функции на всём пространстве дизайна.

Минусы

- ▶ Относительно сложная вычислимость..


ImseGain-MaxVar

$$\mathcal{I}_{IGMV}(\mathbf{x}) = \mathcal{I}_{\rho_2}(\mathbf{x}) * \mathcal{I}_{MV}(\mathbf{x}) = \frac{1}{|\mathbb{X}|} \int_{\mathbb{X}} \hat{K}^2(\mathbf{x}, \mathbf{v}) d\mathbf{v}.$$

- ▶ Нет проблемных членов в знаменателе.
- ▶ По-прежнему ведёт к аппроксимации по всему пространству дизайна.



Поверхность $\mathcal{J}_{IGMV}$

- ▶ Меньше локальных минимумов.
- ▶ Регулярность поведения.




Пример

$$y = 2 + 0.25(x_2 - 5x_1^2)^2 + (1 - 5x_1)^2 + 2(2 - 5x_2)^2 + 7\sin(2.5x_1)$$



Пример

Изначальный экспериментальный дизайн содержит 10 точек.
Строим аппроксимацию регрессией гауссовского процесса.



Пример

Добавлено 70 точек при помощи критерия Максимальной Дисперсии.




Рис.: Изначальная модель




Рис.: Зависимость ошибки от размера обучающей выборки




Рис.: Финальная модель

Вывод

- ▶ Адаптивный дизайн с помощью регрессии гауссовских процессов позволяет значительно снизить издержки получения новых экспериментальных данных.
- ▶ Оптимизируемый функционал необходимо исследовать на регулярность поведения.
- ▶ Предложенный функционал – один из возможных функционалов.

Выводы

- ▶ За счёт оптимального дизайна можно добиться серьёзного улучшения использования данных для решения задачи.
- ▶ Адаптивное сурогатное моделирование позволяет упростить поиск оптимального дизайна за счёт полного и последовательного учёта информации.
- ▶ Оптимальным средством для построения суррогатных моделей служит регрессия гауссовских процессов.